

МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ
(национальный исследовательский университет)
ФИЗТЕХ-ШКОЛА ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
КАФЕДРА ИНТЕЛЛЕКТУАЛЬНЫХ СИСТЕМ

Крейнин Матвей Вадимович

МЕТОДЫ ПРЕДОБУСЛАВЛИВАНИЯ С ЗАТУХАНИЕМ ВЕСОВ

03.03.01 — Прикладные математика и физика

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА БАКАЛАВРА

Научный руководитель:

к.ф.-м.н. А. Н. Безносиков

Москва — 2024

Аннотация

Исследуется сходимость градиентных методов оптимизации первого порядка с предобуславливанием, использующих регуляризацию с затуханием весов. Особое внимание уделяется популярным методам из данного класса, таким как AdamW и OASIS. Рассматриваются три способа добавления регуляризации в методы с предобуславливанием, включая новый, промежуточный способ (масштабированное затухание весов), и изучается вопрос о том, к решению какой задачи сходится каждый из них. Показывается, что методы с затуханием весов оптимизируют не исходную регуляризованную функцию потерь, а изменённую функцию с адаптивным по координатным регуляризатором, и доказывается нижняя оценка расстояния между решениями этих двух задач. Доказываются четыре теоремы о скорости сходимости методов с предобуславливанием и затуханием весов: в невыпуклом и сильно выпуклом случаях, каждый — в детерминированной и стохастической постановках. Проводятся вычислительные эксперименты на эталонных наборах данных и моделях, включая количественную проверку теоретических предсказаний и анализ гиперпараметров, чтобы сравнить рассматриваемые методы на реальных задачах.

Содержание

1	Введение	5
2	Обзор литературы	8
3	Основная часть	9
3.1	Обозначения	9
3.2	Затухание весов	9
3.3	Скорость сходимости методов с предобуславливанием и затуханием весов	11
3.3.1	Детерминированный случай	15
3.3.2	Стохастический случай	18
3.4	Решение, к которому сходятся методы с предобуславливанием и затуханием весов	20
3.5	Эксперименты	22
3.5.1	Методика экспериментов	23
3.5.2	Основной эффект: какую задачу решает затухание весов	25
3.5.3	Проверка леммы о нижней оценке и механизм адаптивной регуляризации	26
3.5.4	Сильно выпуклый случай: линейная скорость (теорема 2)	28
3.5.5	Стохастический случай (теоремы 3 и 4)	29
3.5.6	Свойства масштабированного затухания весов и мосты к практическому Adam	31
3.5.7	Нейронные сети: ResNet-18 на CIFAR-10	32
3.5.8	Обобщающая способность при равном уровне обучения (CIFAR-100)	34
3.5.9	Масштабирование: предобучение GPT-2 и дообучение на GLUE	36
4	Заключение	41

А Приложение	47
А.1 Доказательства лемм	47
А.2 Доказательства теорем	49

1 Введение

Огромная часть машинного обучения основана на решении задачи оптимизации без ограничений

$$\min_{w \in \mathbb{R}^d} f(w). \quad (1)$$

Задачи вида (1) охватывают множество приложений, включая минимизацию эмпирического риска [1], глубокое обучение [2] и задачи обучения с учителем [3], такие как метод наименьших квадратов с регуляризацией [4] или логистическая регрессия [5].

Классический метод решения задачи оптимизации (1) — градиентный спуск:

$$w_{t+1} = w_t - \eta \nabla f(w_t), \quad (2)$$

где $\eta > 0$ — размер шага (шаг обучения).

Задача минимизации (1) может быть трудноразрешимой, особенно когда размер выборки или размерность задачи крайне велики.

В таких случаях подсчёт полного градиента на каждой итерации градиентного спуска становится очень дорогим по времени и вычислительным ресурсам, особенно учитывая, что градиентному спуску часто требуется большое количество итераций для сходимости. В современном машинном обучении, особенно с появлением глубокого обучения, растёт интерес к решению всё более крупных и сложных задач. Популярным решением для таких проблем стал стохастический градиентный спуск [6, 7].

С течением времени методы оптимизации постоянно совершенствовались и развивались, становясь всё более сложными. Одним из важнейших аспектов в оптимизации является правильный подбор размера шага в ходе итерационного процесса. Адаптивные методы с градиентным масштабированием динамически регулируют этот размер шага на основе информации о градиенте. Такое адаптивное поведение, применяемое к каждой переменной, улучшает процесс

оптимизации, позволяя эффективно перемещаться по сложным ландшафтам и обеспечивая оптимальный прогресс для каждой переменной [8]. В частности, эти методы приобрели значительную популярность в области машинного обучения, где преобладают высокоразмерные задачи [9, 10].

Более подробно, под методами с масштабированным градиентом понимаются техники, предполагающие предобуславливание градиента задачи некоторой матрицей D_t , что позволяет учитывать геометрию задачи. В общем случае шаг алгоритмов с предобуславливанием может быть выражен как следующая модификация шага (2):

$$w_{t+1} = w_t - \eta \cdot D_t^{-1} g_t, \quad (3)$$

где g_t — несмещённый стохастический градиент.

Идея использования матрицы масштабирования отсылает нас к методу Ньютона, где $D_t = \nabla^2 f(w_t)$, и квазиньютоновским методам [11]. Однако вычисление и обращение гессиана сопряжено со значительными трудностями, что приводит нас к необходимости использования определённых эвристик в качестве замены матрицы D_t . Примерами таких эвристических методов являются Adagrad [8], Adam [12], RMSProp [13], OASIS [14] и так далее, где стратегии вычисления D_t не требуют точной оценки гессиана. Например, в Adagrad предобуславливатель представлен в виде:

$$D_t = \text{diag} \left\{ \sqrt{\sum_{t'=0}^t g_{t'} \odot g_{t'}} \right\},$$

где $\odot$ — адамарово (покомпонентное) произведение. Отметим, что этот подход использует только стохастические градиенты.

RMSProp и Adam используют похожие идеи:

$$D_t^2 = \beta D_{t-1}^2 + (1 - \beta) \text{diag} \{g_t \odot g_t\},$$

где $\beta \in (0, 1)$ представляет собой степень учёта предыдущих итераций [12].

В OASIS используется другой подход:

$$D_t = \text{diag} \{z_t \odot \nabla^2 f(w_t) z_t\},$$

где z_t — случайный вектор из распределения Радемахера, т.е. каждая компонента z_t^i принимает значения ± 1 с вероятностью $\frac{1}{2}$ [14]. На первый взгляд кажется, что требуется полный гессиан, однако в действительности он не вычисляется явно: произведение $\nabla^2 f(w_t) z_t$ находится дифференцированием скалярной функции $\langle \nabla f(w_t), z_t \rangle$, а $\text{diag}\{z_t \odot \nabla^2 f(w_t) z_t\}$ является несмещённой оценкой диагонали гессиана (оценка Хатчинсона).

Несмотря на преимущества методов предобуславливания, они склонны к переобучению [15]; таким образом, возникает необходимость в их совместном применении с регуляризацией. Этот подход широко применяется для решения различных задач машинного обучения, включая классификацию изображений [16], распознавание речи [17] и обработку естественного языка [18], и показал свою эффективность в улучшении обобщающей способности нейронных сетей [19].

С регуляризацией задача (1) переформулируется как

$$\min_{w \in \mathbb{R}^d} F(w) := f(w) + r(w), \quad (4)$$

где r — функция регуляризации.

В методах с предобуславливанием есть несколько способов добавления регуляризации. Можно включить регуляризатор r в вычисление g_t , и тогда он будет учитываться при вычислении D_t . Этот способ равносильен применению базового метода к оптимизационной задаче (4). Также можно добавить регуляризатор непосредственно в шаг обновления весов, уменьшая норму w [20]. Такой способ регуляризации называется затуханием весов и, что примечательно, оказывается более эффективным в практических задачах. Существует и промежуточный способ учёта регуляризатора, который будет рассмотрен далее в работе.

Несмотря на свою практическую эффективность, методы, использующие затухание весов, относительно мало изучены с точки зрения теории сходимости. В связи с этим возникает ряд исследовательских вопросов:

- *Сходятся ли с теоретической точки зрения методы с предобуславливанием и затуханием весов?*

- Если сходятся, то какова скорость их сходимости?
- К какой задаче они сходятся?

2 Обзор литературы

Сходимость стохастических методов первого порядка подробно изучена [21, 22, 23, 24], в то время как методы с предобуславливанием остаются относительно новыми и малоизученными. Идея адаптивного выбора шага восходит к онлайн-оптимизации [25]; в одной из первых работ по покоординатному предобуславливанию [8] авторы провели тщательный анализ теории сходимости Adagrad. Однако в более поздних работах, например, обсуждающих RMSProp [13] или Adam [12], теоретическим аспектам уделяется мало внимания, либо существующая теория содержит неточности в доказательствах.

Со временем ошибки были исправлены, что привело к разработке надёжных теорий сходимости для методов с предобуславливанием [26, 27]. В другой работе Лоцилов и Хуттер [20] изучили свойства алгоритмов Adam и AdamW в терминах гиперпараметров, а также рассмотрели методы рестартов. Чжан и др. [28] предложили оптимизатор Lookahead — обёртку над произвольным базовым методом (в том числе Adam), в которой «медленные» веса обновляются по нескольким шагам «быстрых». В работе [29] исследователи из Nvidia предложили оптимизатор NovoGrad с послойной адаптацией моментов и отделённым затуханием весов, показавший в их экспериментах прирост качества обучения. Сравнительно недавно были построены теории сходимости для современных методов с предобуславливанием, таких как OASIS [14, 30]. Кроме того, появилась теория, рассматривающая изменяющиеся во времени матрицы предобуславливания [31]. Тем не менее, многие вопросы в этой области остаются без ответа. Некоторые из них сформулированы в конце введения и рассматриваются в настоящей работе.

3 Основная часть

3.1 Обозначения

- Мы используем w^i для обозначения i -й компоненты вектора $w \in \mathbb{R}^d$, где $i \in \overline{1, d}$.
- Для любых $x, y \in \mathbb{R}^d$ скалярное произведение обозначается как $\langle x, y \rangle := \sum_{i=1}^d x^i y^i$.
- L_f — константа гладкости функции f , то есть константа Липшица её градиента: $\|\nabla f(x) - \nabla f(y)\| \leq L_f \|x - y\|$ для всех $x, y \in \mathbb{R}^d$.
- $\|x\| := \sqrt{\langle x, x \rangle}$ — ℓ_2 -норма вектора $x \in \mathbb{R}^d$.
- $\|x\|_A^2 := x^T A x$, где $x \in \mathbb{R}^d$, а $A \in \mathbb{R}^{d \times d}$ — симметричная положительно определённая матрица; $\|x\|_A^* := \sqrt{x^T A^{-1} x}$ — сопряжённая к ней норма.
- Для матрицы $A \in \mathbb{R}^{d \times d}$ через A^{-1} обозначается обратная матрица, через $\|A\|_2$ — спектральная норма; для диагональной матрицы A полагаем $\|A\|_\infty := \max_i |A_{ii}|$.
- Мы используем $A \preceq B$ для двух матриц $A, B \in \mathbb{R}^{d \times d}$, чтобы обозначить, что $x^T A x \leq x^T B x$ для любых $x \in \mathbb{R}^d$.
- $\text{diag}\{\beta_1, \dots, \beta_d\}$ — диагональная матрица с элементами $\beta_1, \dots, \beta_d \in \mathbb{R}$.

3.2 Затухание весов

Как было сказано выше, в методах с предобуславливанием существует несколько техник добавления регуляризации в оптимизируемую функцию. Мы рассмотрим три различных подхода, которые проиллюстрированы в Алгоритме 1 с помощью различных цветов (каждый цвет — это отдельный алгоритм).

Algorithm 1 Различные способы использования предобуславливания с регуляризацией

Require: η — шаг обучения, f — оптимизируемая функция, r — регуляризатор, w_0 — начальная точка

$t = 0$

while w не сойдётся **do**

$t = t + 1$

$g_t \leftarrow$ стохастический градиент f в точке w_{t-1}

$g_t \leftarrow g_t + \nabla r(w_{t-1})$ обычная регуляризация

$D_t \leftarrow$ матрица предобуславливания, построенная по g_t

$w_t \leftarrow w_{t-1} - \eta \cdot D_t^{-1} g_t$ обычная регуляризация

$w_t \leftarrow w_{t-1} - \eta \cdot D_t^{-1} (g_t + \nabla r(w_{t-1}))$ масштабированное затухание весов

$w_t \leftarrow w_{t-1} - \eta \cdot D_t^{-1} g_t - \eta \cdot \nabla r(w_{t-1})$ затухание весов

end while

Если говорить более конкретно, то первая техника регуляризации, показанная синим цветом, заключается в простом добавлении регуляризационного члена к оптимизируемой функции. Этот регуляризатор включается в стохастический градиент и учитывается при вычислении D_t . По сути, этот подход означает применение базового метода оптимизации с предобуславливанием к задаче (4). Вторая техника регуляризации, показанная в Алгоритме 1 оранжевым цветом, является новым подходом. Хотя член регуляризации не влияет на вычисление матрицы предобуславливания D_t , он добавляется к градиенту до умножения на D_t^{-1} . Это означает, что эффективный шаг по регуляризатору масштабируется той же матрицей, что и шаг по градиенту. Последний рассматриваемый нами подход известен как затухание весов; в Алгоритме 1 он подсвечен красным цветом. Как и во втором подходе, матрица D_t вычисляется без учёта регуляризатора, однако здесь регуляризатор добавляется непосредственно на шаге обновления весов, минуя умножение на D_t^{-1} , что позволяет

избежать влияния регуляризации на матрицу предобуславливания.

Учёт влияния регуляризации важен при разработке алгоритмов оптимизации; полученные в настоящей работе результаты могут быть полезны при построении и анализе новых методов этого класса.

3.3 Скорость сходимости методов с предобуславливанием и затуханием весов

Хотя шаг оптимизации весов модели может показаться простым, на него можно посмотреть с другой стороны. Вынесем матрицу D_t^{-1} за скобки, что даёт нам следующий шаг:

$$w_{t+1} = w_t - \eta \cdot D_t^{-1}(\nabla f(w_t) + D_t \nabla r(w_t)). \quad (5)$$

Это подталкивает нас к тому, чтобы ввести новую функцию $\tilde{r}_t$, такую, что $\nabla \tilde{r}_t(w) = D_t \nabla r(w)$, и новую целевую функцию

$$\tilde{F}_t(w) := f(w) + \tilde{r}_t(w), \quad (6)$$

где новая целевая функция $\tilde{F}_t$ меняется на каждом оптимизационном шаге, так как D_t тоже обновляется на каждой итерации.

Новый адаптивный регуляризатор $\tilde{r}_t$ в общем случае, к сожалению, не существует. Поэтому мы наложим ограничения на исходный регуляризатор и структуру предобуславливателя, которые оформлены в виде следующих предположений.

Предположение 1. *(Структура регуляризатора) Регуляризатор r сепарабелен, то есть он может быть представлен в следующем виде:*

$$r(w) = \sum_{i=1}^d r_i(w^i),$$

где $r_i(x) \geq 0$ для $i \in \overline{1, d}$ и $x \in \mathbb{R}$.

Предположение 2. (Структура матрицы предобуславливания) Матрица предобуславливания D_t диагональна:

$$D_t = \text{diag} \{d_t^1, \dots, d_t^d\}.$$

Хотя эти предположения являются достаточно сильными, они выполняются для упомянутых ранее методов с предобуславливанием и затуханием весов, а также для таких популярных функций регуляризации, как регуляризация Тихонова и (сглаженная) LASSO-регуляризация. Скорость сходимости обычно измеряется количеством итераций, которое необходимо для достижения заданного уровня погрешности. Чтобы получить такие оценки, мы должны ввести определённые предположения об оптимизируемой функции потерь. На протяжении всего последующего анализа мы предполагаем, что функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и $r : \mathbb{R}^d \rightarrow \mathbb{R}$ являются гладкими в следующем смысле.

Предположение 3. (L -гладкость)

- Функция f является L_f -гладкой, то есть её градиент липшицев: существует константа $L_f > 0$ такая, что $\forall x, y \in \mathbb{R}^d$

$$\|\nabla f(x) - \nabla f(y)\| \leq L_f \|x - y\|.$$

- Функция r является L_r -гладкой: существует константа $L_r > 0$ такая, что $\forall x, y \in \mathbb{R}^d$

$$\|\nabla r(x) - \nabla r(y)\| \leq L_r \|x - y\|.$$

Из липшицевости градиента стандартным образом следует квадратичная верхняя оценка (лемма о спуске), которой мы будем пользоваться в доказательствах: для L -гладкой функции h и любых $x, y \in \mathbb{R}^d$

$$h(x) \leq h(y) + \langle \nabla h(y), x - y \rangle + \frac{L}{2} \|x - y\|^2. \quad (7)$$

Отметим, что то, что f дважды дифференцируема, в доказательствах не используется; это нужно лишь для корректности предобуславливателей гессианного типа (OASIS, AdaHessian), в которых новая информация для матрицы предобуславливания строится по второй производной.

Для работы в невыпуклом случае нам понадобится ограничение на значения функции регуляризации; оно сформулировано в предположении 4.

Предположение 4. (Ограниченность регуляризатора) Регуляризатор ограничен: существует константа $\Omega > 0$ такая, что $\forall w \in \mathbb{R}^d$

$$|r(w)| \leq \Omega.$$

Замечание. Предположение 4 исключает неограниченные на всём пространстве регуляризаторы (например, регуляризацию Тихонова $r(w) = \frac{\lambda}{2}\|w\|^2$). Оно используется только в невыпуклом случае (теоремы 1 и 3) для контроля дрейфа $\tilde{F}_t$ по t , причём достаточно, чтобы оно выполнялось на множестве, содержащем траекторию метода: если траектория $\{w_t\}$ остаётся в шаре радиуса $R_{\max}$, можно положить $\Omega = \max_{\|w\| \leq R_{\max}} r(w)$. В сильно выпуклом случае (теоремы 2 и 4) это предположение не требуется, и анализ покрывает регуляризацию Тихонова без оговорок.

Мы используем стандартное ограничение на матрицу предобуславливания, которое сформулировано в предположении 5.

Предположение 5. (Ограниченность предобуславливателя) Существуют константы $\alpha, \Gamma \in \mathbb{R} : 0 < \alpha < \Gamma$ такие, что

$$\alpha I \preceq D_t \preceq \Gamma I \Leftrightarrow \frac{I}{\Gamma} \preceq D_t^{-1} \preceq \frac{I}{\alpha}.$$

В работе [31] (в контексте седловых задач), а также в работах [14, 30] показано, что это предположение выполняется для популярных алгоритмов с предобуславливанием, таких как Adam, RMSProp и OASIS (для Adagrad — при дополнительном условии ограниченности градиентов).

В нашем анализе мы рассматриваем два способа обновления матрицы предобуславливания. В первом методе матрица обновляется через квадраты:

$$(D_{t+1})^2 = \beta(D_t)^2 + (1 - \beta)(H_t)^2, \quad (8)$$

где H_t — диагональная матрица, содержащая новую информацию, а $\beta \in [0, 1]$ — параметр импульса (в практических методах $\beta \in (0, 1)$ и близок к 1). Этот

подход используется в Adam, а также в более ранних методах, таких как RMSProp и AdaHessian. Второй способ предполагает использование первых степеней матриц:

$$D_{t+1} = \beta D_t + (1 - \beta) H_t. \quad (9)$$

Этот подход используется в OASIS — недавно предложенном методе. В обоих случаях параметр импульса β обычно выбирается близким к 1, что означает, что D_t незначительно меняется в ходе обучения; формально это утверждение сформулировано в лемме 1.

Выполнение предположения 5 имеет решающее значение для сходимости и теоретического анализа, поэтому в алгоритмах используется принудительное ограничение снизу диагонали матрицы D_t :

$$\hat{D}_{t+1}^{ii} = \max\{\alpha, |D_{t+1}^{ii}|\}. \quad (10)$$

Срезка по модулю согласована с алгоритмом OASIS, в котором оценка диагонали гессиана может иметь отрицательные элементы. Далее всюду, где не оговорено противное, под D_t понимается именно срезанная матрица $\hat{D}_t$; таким образом, предположение 5 выполняется автоматически, если $|H_t^{ii}| \leq \Gamma$ и $\alpha I \preceq \hat{D}_0 \preceq \Gamma I$.

Лемма 1. (Эволюция D_t) *Предположим, что для начальной матрицы D_0 выполнены предположения 2 и 5, матрицы H_t диагональны и $|H_t^{ii}| \leq \Gamma$ для всех i и t , а D_t эволюционирует в соответствии с (8), (10) или (9), (10). Тогда справедливы следующие утверждения:*

1. *предположения 2 и 5 выполняются для $\hat{D}_t$ при всех t ;*
2. $\|\hat{D}_{t+1} - \hat{D}_t\|_\infty \leq \frac{(1-\beta)\Gamma^2}{2\alpha} =: \rho_\beta$ *для (8);*
3. $\|\hat{D}_{t+1} - \hat{D}_t\|_\infty \leq 2(1-\beta)\Gamma =: \rho_\beta$ *для (9).*

Эта лемма доказана в Приложении А.1; при доказательстве мы опираемся на работу [31]. Всюду далее ρ_β обозначает соответствующую правую часть:

$\rho_\beta = \frac{(1-\beta)\Gamma^2}{2\alpha}$ для (8) и $\rho_\beta = 2(1-\beta)\Gamma$ для (9). Подчеркнём, что $\rho_\beta \rightarrow 0$ при $\beta \rightarrow 1$.

С помощью предположений 1 и 2 мы можем доказать существование $\tilde{r}_t$ и, следовательно, $\tilde{F}_t$. Мы оформим это в лемме 2. Функция $\tilde{r}_t$ определена однозначно с точностью до аддитивной константы, и для наших оценок этого достаточно.

Лемма 2. *(Существование $\tilde{r}_t$) Пусть выполняются предположения 1 и 2. Тогда функция $\tilde{r}_t$ существует и имеет следующий вид:*

$$\tilde{r}_t(w) = \sum_{i=1}^d d_t^i r_i(w^i).$$

Используя предположение 3, мы можем гарантировать гладкость $\tilde{r}_t$ и оценить константу Липшица её градиента; это сформулировано в лемме 3.

Лемма 3. *(L-гладкость $\tilde{r}_t$) Пусть выполняются предположения 1, 2, 3, 5. Тогда функция $\tilde{r}_t$ является $L_{\tilde{r}}$ -гладкой с $L_{\tilde{r}} = \Gamma L_r$:*

$$\|\nabla \tilde{r}_t(x) - \nabla \tilde{r}_t(y)\| \leq L_{\tilde{r}} \|x - y\| \quad \forall x, y \in \mathbb{R}^d.$$

В частности, для $\tilde{r}_t$ выполняется неравенство (7) с константой $L_{\tilde{r}}$, а функция $\tilde{F}_t$ является $\tilde{L}$ -гладкой с $\tilde{L} = L_f + \Gamma L_r$.

Чтобы получить дополнительные оценки сходимости, в сильно выпуклом случае мы накладываем предположение 6 на целевую функцию потерь.

Предположение 6. *(Сильная выпуклость) Существует константа $\mu_f > 0$ такая, что $\forall x, y \in \mathbb{R}^d$ выполняется:*

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu_f}{2} \|x - y\|^2.$$

3.3.1 Детерминированный случай

Сначала рассмотрим детерминированную (полноградиентную) постановку: $g_t = \nabla f(w_t)$. Используя введённые предположения, мы доказываем сходимость методов с предобуславливанием и затуханием весов. Наши результаты

сформулированы в теоремах 1 и 2; доказательства можно найти в Приложении А.2.

Теорема 1 (невыпуклый случай). Пусть выполняются предположения 1, 2, 3, 4, 5, метод (5) использует точный градиент ($g_t = \nabla f(w_t)$), а матрица предобуславливания обновляется в соответствии с условиями леммы 1. Пусть шаг обучения удовлетворяет условию

$$\eta < \frac{2\alpha}{\tilde{L}}, \quad \tilde{L} = L_f + \Gamma L_r,$$

где L_f, L_r — константы гладкости функций f и r (константы Липшица их градиентов). Обозначим $\Delta_0 = \tilde{F}_0(w_0) - f^*$, где $w_0 \in \mathbb{R}^d$ — начальная точка, $\tilde{F}_t$ определена в (6), а f^* — оптимальное значение задачи (1), и положим

$$\delta := \Omega \rho_\beta = \begin{cases} \frac{(1-\beta)\Gamma^2\Omega}{2\alpha} & \text{для (8),} \\ 2(1-\beta)\Gamma\Omega & \text{для (9).} \end{cases}$$

Тогда для любой точности ε , удовлетворяющей условию

$$\varepsilon > \frac{\delta\Gamma}{\eta - \frac{\tilde{L}\eta^2}{2\alpha}},$$

число итераций, необходимое для достижения $\min_{0 \leq t \leq T} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \varepsilon$, ограничено величиной

$$T = \mathcal{O} \left(\frac{\Delta_0 \Gamma}{\left(\eta - \frac{\tilde{L}\eta^2}{2\alpha}\right) \left(\varepsilon - \frac{\delta\Gamma}{\eta - \frac{\tilde{L}\eta^2}{2\alpha}}\right)} \right).$$

Замечание. Метод гарантированно уменьшает квадрат нормы градиента изменённой функции $\tilde{F}_t$ лишь до порога $\delta\Gamma/(\eta - \tilde{L}\eta^2/(2\alpha))$, поэтому условие на ε существенно. Поскольку $\delta \propto (1 - \beta)$, порог может быть сделан меньше любой наперёд заданной точности, если выбрать β достаточно близким к 1.

В сильно выпуклом случае мы доказываем линейную скорость сходимости. Подчеркнём принципиальный момент, согласующийся с леммой 4 ниже:

метод с затуханием весов сходится не к решению w^* исходной задачи (4), а к решению $\tilde{w}_t^*$ изменённой задачи — минимизации $\tilde{F}_t$. Именно расстояние до этой (движущейся с ростом t) точки и убывает линейно.

Теорема 2 (сильно выпуклый случай). Пусть выполняются предположения 2, 3, 5, 6, регуляризатор — тихоновский: $r(w) = \frac{\lambda}{2}\|w\|^2$, $\lambda > 0$, метод (5) использует точный градиент ($g_t = \nabla f(w_t)$), а матрица предобуславливания обновляется в соответствии с условиями леммы 1. Обозначим:

$$\tilde{\mu} := \mu_f + \lambda\alpha, \quad \tilde{L} := L_f + \lambda\Gamma, \quad \tilde{w}_t^* := \arg \min_{w \in \mathbb{R}^d} \tilde{F}_t(w), \quad \Omega_0 := \frac{\|\nabla f(0)\|}{\tilde{\mu}},$$

$$R_t^2 := \|w_t - \tilde{w}_t^*\|_{D_t}^2,$$

при этом $\tilde{w}_t^*$ существует, единственно и $\|\tilde{w}_t^*\| \leq \Omega_0$ для всех t . Пусть шаг обучения и параметр импульса удовлетворяют условиям

$$0 < \eta \leq \frac{\tilde{\mu}\alpha^2}{\Gamma\tilde{L}^2}, \quad \rho_\beta \leq \frac{\eta\tilde{\mu}\alpha}{4\Gamma}.$$

Тогда для всех $T \geq 1$

$$R_T^2 \leq \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \frac{64\Gamma^3\lambda^2\Omega_0^2}{\eta^2\tilde{\mu}^4} \rho_\beta^2.$$

В частности, для любого $\varepsilon > 0$, если β выбран так, что второе слагаемое не превосходит $\varepsilon/2$, то $R_T^2 \leq \varepsilon$ после

$$T = \frac{4\Gamma}{\eta\tilde{\mu}} \log \frac{2R_0^2}{\varepsilon} = \mathcal{O}\left(\frac{\Gamma}{\eta\tilde{\mu}} \log \frac{R_0^2}{\varepsilon}\right) \text{ итераций.}$$

Замечание. Второе слагаемое — цена нестационарности предобуславливателя: цель $\tilde{w}_t^*$ дрейфует вместе с D_t , и скорость этого дрейфа контролируется величиной $\rho_\beta \propto (1 - \beta)$ из леммы 1. При $\beta \rightarrow 1$ (или при замороженной матрице $D_t \equiv D$) остаточный член исчезает и метод сходится к $\tilde{w}^*$ линейно, вплоть до машинной точности.

3.3.2 Стохастический случай

Теперь откажемся от точного градиента и проведём анализ в стохастической постановке. Требования к стохастическому градиенту формализованы в следующем предположении.

Предположение 7. (*Стохастический градиент*) Обозначим через $\mathcal{F}_t$ σ -алгебру, порождённую всей случайностью, реализованной строго до розыгрыша g_t (в частности, $g_0, \dots, g_{t-1}$ и случайностью, использованной при построении предобуславливателя, например векторами Радемахера $z_0, \dots, z_t$). Матрица D_t предсказуема, то есть $\mathcal{F}_t$ -измерима (строится по информации, полученной строго до вычисления g_t); при этом w_t также $\mathcal{F}_t$ -измерима. Стохастические градиенты g_t условно несмещены и имеют равномерно ограниченную условную дисперсию:

$$\mathbb{E}[g_t \mid \mathcal{F}_t] = \nabla f(w_t), \quad \mathbb{E}[\|g_t - \nabla f(w_t)\|^2 \mid \mathcal{F}_t] \leq \sigma^2.$$

Замечание. Предсказуемость D_t соответствует «запаздывающему» варианту предобуславливателя и является стандартным приёмом в анализе адаптивных методов; для OASIS она выполняется автоматически, если вектор Радемахера z_t разыгрывается до g_t и независим от него.

Шаг метода принимает вид $w_{t+1} = w_t - \eta D_t^{-1} \hat{g}_t$, где $\hat{g}_t := g_t + D_t \nabla r(w_t)$; при этом в силу предположения 7 и $\mathcal{F}_t$ -измеримости w_t и D_t

$$\mathbb{E}[\hat{g}_t \mid \mathcal{F}_t] = \nabla \tilde{F}_t(w_t), \quad \mathbb{E}[\|\hat{g}_t - \nabla \tilde{F}_t(w_t)\|^2 \mid \mathcal{F}_t] \leq \sigma^2,$$

то есть $\hat{g}_t$ — несмещённая стохастическая оценка градиента изменённой функции с той же дисперсией.

Теорема 3 (стохастический невыпуклый случай). Пусть выполняются предположения 1, 2, 3, 4, 5, 7, а матрица предобуславливания обновляется в соответствии с условиями леммы 1. Пусть шаг обучения удовлетворяет условию

$$0 < \eta \leq \frac{\alpha^2}{\Gamma \tilde{L}}, \quad \tilde{L} = L_f + \Gamma L_r.$$

Тогда в обозначениях теоремы 1

$$\min_{0 \leq t \leq T} \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \frac{2\Gamma\Delta_0}{\eta(T+1)} + \frac{\Gamma\tilde{L}\eta\sigma^2}{\alpha^2} + \frac{2\Gamma\delta}{\eta}.$$

Замечание. Оценка состоит из трёх слагаемых: оптимизационного — порядка $\mathcal{O}(1/(\eta T))$, шумового — порядка $\mathcal{O}(\eta\sigma^2)$ и дрейфового — порядка $\mathcal{O}(\delta/\eta)$. При $\sigma = 0$ и $\delta \rightarrow 0$ восстанавливается скорость $\mathcal{O}(1/T)$ из теоремы 1. Выбирая шаг

$$\eta = \min \left\{ \frac{\alpha^2}{\Gamma\tilde{L}}, \alpha \sqrt{\frac{2\Delta_0}{\tilde{L}\sigma^2(T+1)}} \right\}$$

и β так, что $1 - \beta = \mathcal{O}(\eta^2)$, получаем

$$\min_{0 \leq t \leq T} \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 = \mathcal{O} \left(\frac{\Gamma^2\tilde{L}\Delta_0}{\alpha^2(T+1)} + \frac{\Gamma}{\alpha} \sqrt{\frac{\Delta_0\tilde{L}\sigma^2}{T+1}} \right),$$

то есть скорость $\mathcal{O}(1/\sqrt{T})$, совпадающую по порядку со скоростью стохастического градиентного спуска в невыпуклом случае.

Теорема 4 (стохастический сильно выпуклый случай). Пусть выполняются условия теоремы 2, в которых точный градиент заменён стохастическим, удовлетворяющим предположению 7. Пусть по-прежнему

$$0 < \eta \leq \frac{\tilde{\mu}\alpha^2}{\Gamma\tilde{L}^2}, \quad \rho_\beta \leq \frac{\eta\tilde{\mu}\alpha}{4\Gamma}.$$

Тогда для всех $T \geq 1$

$$\mathbb{E} [R_T^2] \leq \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \frac{8\Gamma\eta\sigma^2}{\tilde{\mu}\alpha} + \frac{64\Gamma^3\lambda^2\Omega_0^2}{\eta^2\tilde{\mu}^4} \rho_\beta^2.$$

В частности, для любого $\varepsilon > 0$, выбирая $\eta \leq \min \left\{ \frac{\tilde{\mu}\alpha^2}{\Gamma\tilde{L}^2}, \frac{\varepsilon\tilde{\mu}\alpha}{24\Gamma\sigma^2} \right\}$ и β так, что третье слагаемое не превосходит $\varepsilon/3$, получаем $\mathbb{E}[R_T^2] \leq \varepsilon$ после $T = \frac{4\Gamma}{\eta\tilde{\mu}} \log \frac{3R_0^2}{\varepsilon}$ итераций.

Замечание. Второе слагаемое — классический «шумовой шар» стохастического градиентного метода с постоянным шагом: его радиус пропорционален

$\eta\sigma^2$ и уменьшается вместе с шагом. Третье слагаемое — дрейф цели $\tilde{w}_t^*$, унаследованный из детерминированного случая (теорема 2); он контролируется выбором $\beta \rightarrow 1$.

Эти теоремы устанавливают сходимость методов с предобуславливанием и затуханием весов при различных предположениях, а также определяют необходимое количество итераций для достижения заданной точности. Для наших задач сам факт сходимости этих методов имеет принципиальное значение.

Однако свойства решения $\tilde{w}_t^*$ задачи

$$\min_{w \in \mathbb{R}^d} \tilde{F}_t(w) = f(w) + \tilde{r}_t(w), \quad (11)$$

к которому сходятся эти методы, требуют более глубокого исследования; ему посвящён следующий подраздел.

3.4 Решение, к которому сходятся методы с предобуславливанием и затуханием весов

В предыдущем подразделе мы доказали сходимость методов с предобуславливанием и затуханием весов. При этом, как подчёркивалось выше, такие методы сходятся не к решению w^* исходной регуляризованной задачи (4), а к решению $\tilde{w}_t^*$ изменённой задачи (11). Содержательно это объясняется следующим образом. Мы получили новую целевую функцию потерь (11), в которой величина регуляризации динамически меняется от шага к шагу на основании матрицы предобуславливания. Поскольку матрица D_t строится по стохастическим градиентам (или оценкам кривизны), эффективный по координатам штраф $d_t^i r_i(w^i)$ оказывается тем больше, чем больше градиент по данной координате, и тем меньше, чем он ближе к нулю. Иными словами, регуляризация почти не штрафует те веса модели, по которым градиент вышел на значения, близкие к нулю. За счёт этого метод делает больший эффективный шаг по координатам, где стохастический градиент ещё далёк от нуля, то есть пока оптимизация по ним не достигла окрестности стационарной точки. Это порождает более

разнообразную траекторию обновления весов, которая на практике часто приводит к лучшему итоговому качеству; эксперименты (раздел 3.5) уточняют, что выигрыш реализуется прежде всего через лучшую достижимую точку оптимизации, а не через лучшее обобщение при одинаковом уровне подгонки. Эти рассуждения подтверждаются экспериментами, подробно описанными в разделе 3.5.

Оценим расстояние между решениями задач (4) и (11). Оценка опирается на предположение 3 и свойства матрицы D_t .

Лемма 4. *(Нижняя оценка расстояния между решениями) Пусть выполняются предположения 1, 2 и 3, задача (4) имеет решение w^* , а задача (11) при фиксированном t имеет решение $\tilde{w}_t^*$. Тогда расстояние между решениями ограничено снизу:*

$$L_F \|\tilde{w}_t^* - w^*\| \geq \|(I - D_t) \nabla r(\tilde{w}_t^*)\|,$$

где $L_F = L_f + L_r$ — константа Липшица градиента функции $F = f + r$.

Из леммы видно, что учёт регуляризатора непосредственно в стохастическом градиенте (и, как следствие, в матрице преобуславливания D_t) соответствует решению исходной задачи (4), тогда как затухание весов приводит метод к альтернативному решению $\tilde{w}_t^*$. Расхождение между этими решениями контролируется тем, насколько матрица D_t далека от единичной: правая часть оценки обращается в нуль при $D_t = I$ и растёт вместе с $\|(I - D_t) \nabla r(\tilde{w}_t^*)\|$. Отметим, что лемма 1 гарантирует лишь малость пошаговых изменений D_t при $\beta \rightarrow 1$, но не сходимости к пределу; более того, эксперименты (раздел 3.5) показывают, что поэлементно матрица D_t и не стабилизируется: в детерминированном режиме она медленно дрейфует к нижней срезке, а в стохастическом — флуктуирует на уровне, определяемом шумом градиента. Стабилизируются её типичный масштаб и распределение элементов. Именно поэтому лемма 4 сформулирована для фиксированного шага t и не требует существования предела; анализ распределения элементов D_t на стационарном участке траектории даёт представление о том, к какому решению сходится метод с затуханием весов и насколько оно отличается от w^* .

3.5 Эксперименты

Мы рассматриваем алгоритмы Adam [12] и OASIS [14], а также их вариации. Их основное отличие заключается в способе вычисления матрицы предобуславливания: в Adam это диагональная матрица, составленная из экспоненциально усреднённых квадратов компонент градиента (правило (8)), в OASIS — стохастическая оценка диагонали гессиана по векторам из распределения Радемахера (правило (9)). Три варианта регуляризации для Adam и OASIS приведены в Алгоритме 2 и Алгоритме 3 соответственно; цветовая схема согласована с Алгоритмом 1: **синий** — обычная регуляризация (L2), **оранжевый** — масштабированное затухание весов (WH), **красный** — затухание весов (W).

Algorithm 2 Различные способы добавления регуляризации для Adam

Require: $\eta, \beta_1, \beta_2, \epsilon$ — гиперпараметры, f — функция потерь, r — регуляризатор, w_0 — начальная точка

$$m_0 = 0, v_0 = 0, t = 0$$

while w не сойдётся **do**

$$t = t + 1$$

$$g_t = \nabla f(w_{t-1}) + \nabla r(w_{t-1})$$

AdamL2

$$m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$$

$$v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} + \nabla r(w_{t-1})$$

AdamWH

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$w_t = w_{t-1} - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}} - \nabla r(w_{t-1})$$

AdamW

end while

Algorithm 3 Различные способы добавления регуляризации для OASIS

Require: $\eta_0, D_0, \beta_2, \alpha$ — гиперпараметры, f — функция потерь, r — регуляризатор, w_0 — начальная точка, $\theta_0 = +\infty$ — начальное значение для адаптивного шага

$$\hat{D}_0^{ii} = \max\{\alpha, |D_0^{ii}|\}, \forall i = \overline{1, d}$$

$$w_1 = w_0 - \eta_0 \hat{D}_0^{-1} \nabla f(w_0)$$

for $k = 1, 2, \dots$ **do**

$$g_k = \nabla f(w_k) + \nabla r(w_k) \quad \text{OASISL2}$$

$z_k \sim$ Радемахер, т.е. $z_k^i \in \{-1, 1\}$ равновероятно

$$D_k = \beta_2 D_{k-1} + (1 - \beta_2) \cdot \text{diag} \left(z_k \odot \nabla^2 (f(w_k) + r(w_k)) z_k \right) \quad \text{OASISL2}$$

$$\hat{D}_k^{ii} = \max\{\alpha, |D_k^{ii}|\}, \forall i = \overline{1, d}$$

$$\eta_k = \min \left\{ \sqrt{1 + \theta_{k-1}} \cdot \eta_{k-1}; \frac{\|w_k - w_{k-1}\|_{\hat{D}_k}}{2 \|\nabla f(w_k) - \nabla f(w_{k-1})\|_{\hat{D}_k}^*} \right\}$$

$$w_{k+1} = w_k - \eta_k \hat{D}_k^{-1} g_k \quad \text{OASISL2}$$

$$w_{k+1} = w_k - \eta_k \hat{D}_k^{-1} (g_k + \nabla r(w_k)) \quad \text{OASISWH}$$

$$w_{k+1} = w_k - \eta_k \hat{D}_k^{-1} g_k - \eta_k \nabla r(w_k) \quad \text{OASISW}$$

$$\theta_k = \frac{\eta_k}{\eta_{k-1}}$$

end for

Отметим, что в синем варианте (OASISL2) регуляризатор участвует и в градиенте g_k , и в оценке гессиана (то есть в матрице D_k) — это в точности применение базового метода к задаче (4). В оранжевом и красном вариантах матрица D_k строится только по f , а $g_k = \nabla f(w_k)$.

Связь теоретических утверждений с экспериментами резюмирует таблица 1.

3.5.1 Методика экспериментов

Все эксперименты выполнены на графических ускорителях NVIDIA GeForce RTX 3090. На задачах малой размерности (данный и следующие четыре

Таблица 1: Соответствие «утверждение — эксперимент — иллюстрация»

Утверждение	Эксперимент / иллюстрация
Затухание весов оптимизирует $\tilde{F}_t$, а не F (теоремы 1–4)	Рис. 1, 2 (малые задачи), 10 (ResNet), 12, 13 (GPT-2)
Нижняя оценка расстояния решений (лемма 4)	Рис. 3: 27 конфигураций, 0 нарушений
Механизм адаптивного штрафа λd^i	Рис. 4 (корреляция с частотой признака), 12 (авто-«no-decay» для LayerNorm)
Линейная скорость к $\tilde{w}_t^*$ (теорема 2)	Рис. 6
Шумовые члены (теоремы 3, 4)	Рис. 7, 8: наклоны 1.00–1.03
Поведение D_t (лемма 1)	Скейлинг $\ \hat{D}_{t+1} - \hat{D}_t\ _\infty \propto (1 - \beta)$ (в тексте); рис. 5 — поведение масштаба $\hat{D}_t$
Свойства и порог устойчивости WH	Таблица 2, рис. 9, GPT-2 и GLUE
Практическое преимущество AdamW	Рис. 9, таблицы 3, 4, рис. 11

подраздела) вычисления проводятся в двойной точности (float64) и, если не оговорено противное, с полным градиентом; эксперименты с нейронными сетями (три заключительных подраздела) используют собственные протоколы, описанные по месту. Матрица предобуславливания срезается с двух сторон: $\hat{D}_t = \text{clip}(|D_t|, \alpha, \Gamma)$ с $\alpha = 10^{-8}$, $\Gamma = 10^3$ — двусторонняя срезка обеспечивает контролируемость констант из предположения 5. Критерий $\|\nabla \tilde{F}_t\|^2 = \|\nabla f(w_t) + \hat{D}_t \nabla r(w_t)\|^2$ всюду вычисляется с той же матрицей $\hat{D}_t$, которая использована в шаге метода на данной итерации.

Задачи: (а) диагональная квадратичная $f(w) = \sum_i (\frac{a_i}{2}(w^i)^2 - b_i w^i)$, $d = 100$, спектр лог-равномерный, $\kappa = a_{\max}/a_{\min} \in \{10, 10^3\}$ — для неё решения обеих задач известны аналитически: $w^{*,i} = b_i/(a_i + \lambda)$ и $\tilde{w}^{*,i} = b_i/(a_i + \lambda d^i)$; (б) плотная квадратичная с тем же спектром; (в) логистическая регрессия с регуляризацией Тихонова на наборе данных **mushrooms** из LIBSVM (8124 объектов, $d = 112$, $\lambda = 0.04$); (г) для стохастических экспериментов — гладкая

невыпуклая задача классификации $f(w) = \frac{1}{n} \sum_j (1 - \tanh(y_j x_j^T w))$ с ограниченным сепарабельным регуляризатором $r(w) = \lambda \sum_i \frac{(w^i)^2}{1+(w^i)^2}$ (удовлетворяет предположению 4; используется для теоремы 3), а также диагональная квадратичная задача с аддитивным гауссовским шумом с нулевым средним и контролируемой дисперсией σ^2 (проверка шумовых членов; для теоремы 4 — с регуляризацией Тихонова). Точные решения w^* и $\tilde{w}^*$ вычисляются методом Ньютона до нормы градиента 10^{-12} ; шаг η подбирается по сетке отдельно для каждого метода; каждая кривая — медиана по 5 запускам из случайных начальных точек.

Валидация стенда: для диагональной квадратичной задачи траектория AdamW после стабилизации матрицы $\hat{D}$ совпадает с аналитическим решением $\tilde{w}^*(\hat{D})$ с относительной точностью $8 \cdot 10^{-17}$ (машинная точность), при этом $\|\nabla \tilde{F}\|^2 \approx 10^{-30}$, а $\|\nabla F\|^2 = 0.11$ — отношение критериев составляет 10^{29} .

3.5.2 Основной эффект: какую задачу решает затухание весов




Рис. 1: Семейство Adam на задаче `mushrooms`: квадрат нормы градиента исходной функции F (слева) и изменённой функции $\tilde{F}_t$ (справа). Линия — медиана, заливка — межсидовый разброс (min–max) по 5 запускам из случайных начальных точек

Рис. 1 и 2 демонстрируют главное утверждение работы. У методов с затуханием весов (AdamW, OASISW) норма градиента исходной функции F не




Рис. 2: Семейство OASIS на задаче **mushrooms**: квадрат нормы градиента исходной функции F (слева) и изменённой функции $\tilde{F}_t$ (справа). Линия — медиана, заливка — межсидовый разброс (min–max) по 5 запускам

убывает — она стабилизируется на ненулевом уровне порядка $\|(I - D_t)\nabla r(w_t)\|$, что согласуется с леммой 4, — тогда как квадрат нормы градиента изменённой функции $\tilde{F}_t$ монотонно убывает на 10–16 порядков, в согласии с теоремами 1 и 2. У метода с обычной регуляризацией (L2) картина зеркальная: убывает $\|\nabla F\|^2$ (до уровня, задаваемого дискретизацией шага, см. ниже), а $\|\nabla \tilde{F}_t\|^2$ выходит на плато. Промежуточный метод (WH) обсуждается отдельно ниже. Такое же поведение наблюдается на обеих квадратичных задачах для OASIS-семейства; для Adam-семейства на плохо обусловленных квадратичных задачах ($\kappa = 10^3$) контраст критериев при умеренных значениях шага частично маскируется плато, обусловленным дискретизацией (осцилляции Adam с постоянным шагом), и предельная точка проверяется напрямую — сравнением с аналитическим $\tilde{w}^*$, см. выше.

3.5.3 Проверка леммы о нижней оценке и механизм адаптивной регуляризации

Для 27 конфигураций (3 задачи $\times$ 9 значений $\lambda \in [10^{-4}, 1]$) вычислены точные решения w^* и $\tilde{w}^*$ и обе части неравенства леммы 4. Неравенство выполнено во всех случаях без исключения (рис. 3, слева), причём оценка содержательна:




Рис. 3: Проверка леммы 4: слева — $L_F \|\tilde{w}^* - w^*\|$ против $\|(I - D) \nabla r(\tilde{w}^*)\|$ (все точки выше диагонали), справа — отношение правой части к левой

отношение правой части к левой достигает 0.29 при больших λ (рис. 3, справа), а расстояние $\|\tilde{w}^* - w^*\|$ монотонно растёт с λ .




Рис. 4: Механизм адаптивной регуляризации (AdamW, mushrooms): распределение элементов D на стационарном участке (слева), связь d^i с частотой признака (в центре, корреляция Спирмена 0.876), сравнение профилей весов AdamW и AdamL2 (справа)

Рис. 4 иллюстрирует интерпретацию из раздела о решении: элементы d^i стационарной матрицы предобуславливания сильно коррелируют с частотой соответствующих признаков (корреляция Спирмена 0.876, $p \approx 10^{-36}$), то есть эффективный покоординатный штраф λd^i мал именно там, где градиенты малы. Как следствие, на редких признаках решение AdamW имеет средний

модуль веса в ≈ 50 раз больший, чем решение AdamL2 (3.47 против 0.07): затухание весов практически не штрафует редко активируемые координаты.




Рис. 5: Поэлементная эволюция $\hat{D}_t$: относительное расстояние до финальной матрицы. Матрица не сходится поэлементно (в детерминированном режиме дрейфует к срезке, в стохастическом флуктуирует), но стабилизируются её масштаб и распределение элементов

Отдельно проверено поведение самой матрицы D_t (рис. 5): поэлементного предела $\lim_t D_t$ в строгом смысле не наблюдается — в детерминированном полноградиентном режиме $v_t \rightarrow 0$ вблизи стационарной точки и $\hat{D}_t$ медленно дрейфует к нижней срезке, а в стохастическом режиме $\hat{D}_t$ выходит на уровень, определяемый шумом градиента, и флуктуирует вокруг него. Это оправдывает формулировку леммы 4 для фиксированного шага t (без предположения о существовании предела).

3.5.4 Сильно выпуклый случай: линейная скорость (теорема 2)

На квадратичной задаче с точно известными константами μ_f, L_f величина $R_t^2 = \|w_t - \tilde{w}_t^*\|_{D_t}^2$ (где $\tilde{w}_t^*$ пересчитывается по текущей D_t прямым решением линейной системы) убывает линейно на 25–28 порядков до машинной точности




Рис. 6: Линейная сходимость AdamW к решению изменённой задачи $\tilde{w}_t^*$ (движущейся цели) для трёх конфигураций (α, Γ) при шаге и β , удовлетворяющих условиям теоремы 2; пунктир — теоретическая скорость $(1 - \eta\tilde{\mu}/(4\Gamma))^t$

(рис. 6). Эмпирическая скорость сходимости во всех конфигурациях (α, Γ) превышает гарантию теоремы 2 в 11–207 раз — теоретическая оценка является корректной (хотя и консервативной) верхней границей числа итераций. Подчеркнём методическую деталь: расстояние измеряется именно до $\tilde{w}_t^*$, а не до решения w^* исходной задачи — до последнего метод не сходится (см. рис. 1).

3.5.5 Стохастический случай (теоремы 3 и 4)

Для проверки стохастических теорем используется аддитивный несмещённый шум с контролируемой дисперсией σ^2 и «запаздывающий» предобуславливатель (предположение 7). Шумовой член теоремы 3 проверен на предобуславливателе OASIS-типа, который не зависит от шума градиента (оценка гессиана): измеренное плато $\mathbb{E}\|\nabla\tilde{F}_t\|^2$ масштабируется по η с наклоном 1.00 и по σ^2 с наклоном 1.00 в двойных логарифмических координатах (рис. 7) — в точном согласии с членом $\Gamma\tilde{L}\eta\sigma^2/\alpha^2$. Для теоремы 4 стационарный уровень $\mathbb{E}\|w_t - \tilde{w}_t^*\|_{D_t}^2$ растёт с наклоном 1.03 по η , масштабируется в точности как σ^2 и всюду лежит ниже теоретической границы (рис. 8).

Два замечания об области применимости оценок. Во-первых, для Adam-типа предобуславливателя (D строится по квадратам стохастических градиен-




Рис. 7: Шумовой член теоремы 3: плато $\mathbb{E}\|\nabla \tilde{F}_t\|^2$ в зависимости от η при разных уровнях шума σ (OASIS-тип предобуславливателя). Наклоны по η равны 1.00, по σ^2 — 1.00




Рис. 8: Шумовой шар теоремы 4: стационарное значение $\mathbb{E}\|w_t - \tilde{w}_t^*\|_{D_t}^2$ в зависимости от η ; пунктир — верхняя граница $8\Gamma\eta\sigma^2/(\tilde{\mu}\alpha)$

тов) зависимость плато от η на практике слабее линейной: $\hat{D}_t$ сам подстраивается под уровень шума и частично «самонормализует» шаг; граница теоремы 3 при этом выполняется, но по η консервативна. Во-вторых, дрейфовые члены

с ρ_β (теоремы 1–4) — оценки худшего случая: сама лемма 1 подтверждается напрямую (измеренное $\max_t \|\hat{D}_{t+1} - \hat{D}_t\|_\infty$ масштабируется как $1 - \beta$ и никогда не нарушает границу), однако в детерминированном полноградиентном режиме Adam-типа $v_t \rightarrow 0$ у стационарной точки, матрица останавливается на срезке и дрейфовое плато вовсе не проявляется, а в стохастическом режиме уровень плато определяется шумовым членом.

3.5.6 Свойства масштабированного затухания весов и мосты к практическому Adam

Эксперименты позволяют охарактеризовать предложенный промежуточный способ регуляризации. Во-первых, его стационарная точка — решение w^* исходной задачи (4): условие стационарности (неподвижной точки) $\hat{D}_t^{-1}(\nabla f(w) + \nabla r(w)) = 0$ эквивалентно $\nabla F(w) = 0$. На mushrooms при индивидуально подобранных шаге и срезке AdamWH и AdamL2 сходятся к w^* с точностью 10^{-15} , тогда как AdamW уходит от w^* на расстояние 6–10. На рис. 1 (слева) у AdamWH $\|\nabla F\|^2 \rightarrow 10^{-31}$; плато AdamL2 на том же рисунке ($\sim 10^{-4}$) обусловлено дискретизацией при выбранном для него шаге и не является свойством предельной точки. При этом, в отличие от L2, регуляризатор не искажает матрицу предобуславливания.

Во-вторых, у метода есть ограничение устойчивости: регуляризатор проходит через $\hat{D}_t^{-1}$, и на «мёртвых» координатах (где градиент мал и $\hat{D}_t$ упирается в нижнюю срезку α) эффективный шаг по регуляризатору возрастает до $\eta\lambda/\alpha$. Это даёт простое необходимое условие устойчивости $\eta\lambda/\alpha < 2$, которое подтверждается экспериментом (таблица 2): во всех пяти конфигурациях, включая пограничную $\eta\lambda/\alpha = 1$, наблюдение совпадает с предсказанием правила. Практический вывод: WH следует использовать с умеренной нижней срезкой (или ϵ), $\alpha \gtrsim \eta\lambda$.

Наконец, проверены «мосты» между теоретической постановкой и практическим Adam: замена жёсткой срезки $\max\{\alpha, \cdot\}$ на практическую добавку $\sqrt{v} + \epsilon$, включение момента $\beta_1 = 0.9$ и коррекции смещения не меняют каче-

Таблица 2: Порог неустойчивости AdamWH (*mushrooms*, $\eta = 0.03$, $\lambda = 0.1$)

α	$\eta\lambda/\alpha$	Предсказание (> 2 — расходимость)	Наблюдение
10^{-8}	$3 \cdot 10^5$	расходится	расходится
10^{-4}	30	расходится	расходится
$3 \cdot 10^{-3}$	1	устойчив	устойчив
10^{-2}	0.3	устойчив	устойчив
10^{-1}	0.03	устойчив	устойчив

ственной картины — норма $\|\nabla \tilde{F}_t\|^2$ у AdamW падает на 10–21 порядок во всех вариантах, а $\|\nabla F\|^2$ стабилизируется на ненулевом уровне.

3.5.7 Нейронные сети: ResNet-18 на CIFAR-10

Перейдём к нейронным сетям и проверим, что найденные эффекты сохраняются при их обучении. Сеть ResNet-18 [32] (вариант для CIFAR: свёртка 3×3 на входе, без начального пулинга) обучается на CIFAR-10 [33]: 50 эпох, размер батча 128, стандартные аугментации, косинусное расписание шага с разогревом 5 эпох, $(\beta_1, \beta_2, \epsilon) = (0.9, 0.999, 10^{-8})$, смешанная точность. Сравниваются AdamL2, AdamW и AdamWH на полной сетке $\eta \in \{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}\} \times \lambda \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1\}$ — по 30 пар (η, λ) на метод, всего 90 прогонов. Критерии $\|\nabla F\|^2$ и $\|\nabla \tilde{F}_t\|^2$ измеряются на фиксированном пробном батче из 2048 обучающих примеров без аугментаций, причём в качестве $\hat{D}_t$ берётся ровно та матрица $\sqrt{\hat{v}_t} + \epsilon$, что используется в шаге оптимизатора.

Результаты (рис. 9) воспроизводят и уточняют известную картину [20]. Лучшую точность даёт AdamW: по трём запускам в оптимуме ($\eta = 10^{-2}$, $\lambda = 0.1$) — $93.9 \pm 0.3\%$ (максимум 94.2%) против $93.8 \pm 0.1\%$ у AdamWH и $93.5 \pm 0.1\%$ у AdamL2; преимущество AdamW над AdamL2 превышает разброс между запусками. Главное различие — в форме областей оптимума. У AdamW качество практически нечувствительно к λ на пяти порядках: даже при $\lambda = 1$




Рис. 9: Итоговая точность на тесте (%) в осях (η, λ) для трёх способов регуляризации; звёздочка — лучшая конфигурация метода

средняя по η точность составляет 89.8% — это и есть «развязка» λ от η . У AdamL2 область оптимума диагональна: с ростом λ оптимальный шаг сползает вниз (регуляризатор попадает в D_t и меняет эффективный масштаб шага), а при $\lambda = 1$ средняя точность падает до 38.9%; в точке $(\eta, \lambda) = (10^{-2}, 0.1)$ прямое сравнение даёт 94.2% у AdamW против 19.7% у AdamL2. У AdamWH собственной развязки нет: при малых λ он ведёт себя как AdamW и AdamL2, но правая часть карты обрушивается вдоль линии $\eta\lambda \approx \text{const}$ (при $\lambda = 1$ средняя точность 10.8% — уровень случайного угадывания) — это то же ограничение устойчивости, что и в таблице 2, — роль нижней срезки α на практике играет реализовавшийся масштаб знаменателя $\sqrt{\hat{v}_t} + \epsilon$.

Основной эффект теории воспроизводится на уровне всей сети, а не отдельного слоя (рис. 10): к концу обучения лучшей конфигурации AdamW квадрат нормы стохастического градиента $\|\nabla f\|^2$ на пробном батче падает на четыре порядка (с $3.6 \cdot 10^2$ до $1.9 \cdot 10^{-2}$), норма $\|\nabla \tilde{F}_t\|^2$ убывает вместе с ним, тогда как $\|\nabla F\|^2 = \|\nabla f + \lambda w\|^2$ выходит на плато $\sim 6 \cdot 10^2$ — расхождение критериев к концу обучения составляет от $9 \cdot 10^3$ до $3.3 \cdot 10^4$ раз по трём запускам. Послойная статистика $\hat{D}_t$ подтверждает механизм адаптивной регуляризации и на ResNet-18: медианные значения $\hat{d}^i$ различаются между группами слоёв на три порядка (от $5 \cdot 10^{-6}$ в глубоких свёрточных блоках до $9 \cdot 10^{-3}$ в первом батч-нормировочном слое), то есть эффективный по координатный штраф




Рис. 10: Два критерия по ходу обучения лучшей конфигурации AdamW (ResNet-18, CIFAR-10, вся сеть): $\|\nabla F\|^2$ стабилизируется, $\|\nabla \tilde{F}_t\|^2$ убывает вместе с $\|\nabla f\|^2$. Линия — медиана, заливка — разброс по 3 запускам

$\lambda \hat{d}^i$ сильно неоднороден по сети — в полном согласии с интерпретацией из раздела о решении. Отдельная серия запусков с постоянным шагом и $\beta_2 \in \{0.9, 0.99, 0.999, 0.9999\}$ подтверждает сделанное выше замечание об области применимости дрейфовых оценок: уровень плато $\|\nabla \tilde{F}_t\|^2$ на сети определяется шумом мини-батчей и практически не зависит от β_2 (наклон 0.15 в двойных логарифмических координатах), оставаясь при этом на полтора–два порядка ниже $\|\nabla F\|^2$.

3.5.8 Обобщающая способность при равном уровне обучения (CIFAR-100)

Чтобы отделить влияние точки сходимости от скорости оптимизации, методы сравнивались на CIFAR-100 (100 классов, регуляризация важнее) для двух архитектур — ResNet-18 (60 эпох) и компактного визуального трансформера ViT-Tiny (5.4М параметров, 100 эпох, RandAugment, сглаживание меток 0.1). Гиперпараметры каждого метода подбирались по сетке 3×3 ; в качестве внешнего ориентира добавлен SGD с моментом. Итоги по 5 запускам — в таблице

3.

Таблица 3: CIFAR-100: лучшая точность на тесте, среднее $\pm$ ст. отклонение по 5 запускам

Метод	ResNet-18	ViT-Tiny
SGD-M (ориентир)	76.8 ± 0.2	64.1 ± 0.6
AdamL2	73.5 ± 0.3	58.2 ± 0.5
AdamW	75.3 ± 0.3	64.5 ± 0.3
AdamWH	73.3 ± 0.3	15.7 ± 1.8

Внутри Adam-семейства ранжирование устойчиво: AdamW превосходит AdamL2 на +1.8 п.п. на ResNet-18 и на +6.3 п.п. на ViT-Tiny (трансформер заметно чувствительнее к способу регуляризации); на свёрточной сети классический SGD с моментом остаётся сильнейшим, на трансформере AdamW выходит на его уровень. Срезы «точность на тесте при первом достижении заданного train loss» уточняют природу преимущества: при *совпадающем* уровне подгонки обобщение методов близко (различия $\lesssim 1\text{--}1.5$ п.п.), однако связанная регуляризация мешает самой оптимизации — AdamL2 на ViT-Tiny за весь бюджет обучения не достигает train loss 2.0, который AdamW и SGD проходят задолго до конца обучения. Иными словами, на этих задачах преимущество отделённого затухания весов — это в первую очередь преимущество достижимой точки (более низкий train loss при не худшем обобщении), а не лучшее обобщение при фиксированной подгонке. AdamWH на ViT-Tiny деградирует даже при малом $\eta\lambda$: у трансформера с сильными аугментациями распределение $\hat{D}_t$ имеет тяжёлый хвост малых значений, и покоординатный порог устойчивости нарушается на части параметров.

3.5.9 Масштабирование: предобучение GPT-2 и дообучение на GLUE

Наконец, проверим, что найденные эффекты сохраняются на масштабе языковых моделей. Модель GPT-2 (124М параметров: 12 слоёв, размерность 768, контекст 1024) предобучается на корпусе FineWeb-Edu (3.2 млрд токенов, токенизация GPT-2 BPE): батч 0.245М токенов, косинусное расписание с разогревом, $(\beta_1, \beta_2, \epsilon) = (0.9, 0.95, 10^{-8})$, смешанная точность. Гиперпараметры (η, λ) подбирались для каждого метода отдельно на пилотной сетке (13 запусков по 100М токенов); основные запуски — 1.5 млрд токенов, по два запуска на метод из разных начальных точек.

Пилотная сетка воспроизводит выводы предыдущих разделов на новом масштабе. AdamW практически нечувствителен к гиперпараметрам: изменение λ в 10 раз (от 0.01 до 0.1) меняет валидационную ошибку лишь на 0.0002 пата (5.8346 против 5.8348), тогда как AdamL2 заметно хуже и сильно λ -чувствителен (6.86 при $\lambda = 0.01$ и 8.06 при $\lambda = 0.1$): регуляризатор, попадающий в D_t , искажает эффективный шаг. AdamWN расходится во всех пяти испытанных конфигурациях, включая $\lambda = 10^{-3}$: у языковой модели уже на инициализации есть параметры с почти нулевыми градиентами (строки эмбедингов редких токенов), для которых покоординатный порог устойчивости нарушен на несколько порядков. Правило устойчивости работает и в «лечащую» сторону: поднятие ϵ до 10^{-4} – $10^{-3} \gg \eta\lambda$ полностью устраняет расходимость (ни одного пап), — однако вылеченный метод неконкурентоспособен: при том же бюджете токенов он останавливается на валидационной ошибке 7.22 ($\epsilon = 10^{-4}$) и 7.85 ($\epsilon = 10^{-3}$) против 5.83 у AdamW — большая аддитивная константа в знаменателе сплюсчивает предобуславливатель и уничтожает саму адаптивность. Вместе с результатами на *mushrooms* (таблица 2) и CIFAR-10 (рис. 9) это очерчивает область применимости масштабированного затухания весов: рабочее окно λ сужается вместе с типичным масштабом градиентов, и на предобучении языковых моделей рабочей точки не остаётся — либо расходимость (малый ϵ), либо деградация (большой ϵ).




Рис. 11: Предобучение GPT-2 124M на FineWeb-Edu: валидационная ошибка (среднее и разброс по двум запускам на метод)

В основных запусках (рис. 11) AdamW достигает валидационной ошибки 3.492 (два запуска: 3.4923 и 3.4918 — межсидовый разброс 0.0005), тогда как AdamL2 останавливается на уровне 6.68 ± 0.01 — разрыв составляет 3.19 ната. Включение регуляризатора в градиент (и, как следствие, в предобуславливатель) на этом масштабе практически блокирует обучение при том же λ , при котором отделённое затухание весов работает без потерь.

Критерии и послойные статистики для GPT-2 измеряются, как и ранее, на фиксированном пробном батче (8×1024 токенов валидационной выборки) с той же $\hat{D}_t$, что и в шаге. Поведение критериев (рис. 12, слева) согласуется с теоремами 3–4: $\|\nabla \tilde{F}_t\|^2$ убывает вместе с $\|\nabla f\|^2$, а $\|\nabla F\|^2$ выходит на ненулевое плато. Послойная картина (справа) добавляет содержательный вывод: в конце обучения отношение критериев для параметров LayerNorm составляет 450–1400, для эмбеддингов ≈ 14 , для attention- и MLP-весов — лишь 1.5–3. Иными словами, адаптивная регуляризация $\tilde{r}_t$ автоматически «выключает» штраф именно там, где градиенты малы, — для LayerNorm-параметров и эмбеддингов, то есть decoupled-механизм сам воспроизводит практику ручного исключения этих групп параметров из затухания весов (списки по-decay), которую обычно




Рис. 12: AdamW на GPT-2: эволюция глобальных критериев (слева) и отношение $\|\nabla F\|^2 / \|\nabla \tilde{F}_t\|^2$ по группам параметров в конце обучения (справа)

приходится программировать явно.

Устойчивость эффекта к рестартам проверена ветвлением обучения: из финального чекпойнта AdamW запущены три продолжения по 150M токенов с различными потоками данных (рис. 13). Продолжения запускались с постоянным ненулевым шагом (расписание сброшено), поэтому первая точка веток (3.516) лежит выше финальной точки основного запуска (3.492). Все три ветки ведут себя согласованно: валидационная ошибка убывает одинаково ($3.516 \rightarrow 3.506 \pm 0.001$), а отношение критериев $\|\nabla F\|^2 / \|\nabla \tilde{F}_t\|^2$ совпадает до второго знака (3.33–3.36), — наблюдаемые эффекты являются свойством метода, а не конкретной случайной траектории.

Дополнительно методы сравнивались в режиме дообучения: RoBERTa-base на пяти задачах GLUE (RTE, MRPC, CoLA, STS-B, SST-2), η и λ подбирались для каждой пары (задача, метод) по сетке, итоговые значения — среднее $\pm$ стандартное отклонение по 5 запускам (SST-2 — по 3; таблица 4). AdamW не уступает AdamL2 ни на одной задаче, а на CoLA и STS-B превосходит статистически значимо (парный критерий Стьюдента по сидам: $p = 0.010$ и $p = 0.015$); большой разброс на RTE — известная нестабильность этой малой задачи. AdamWH даже при $\lambda = 10^{-3}$ существенно отстаёт: в режиме дообу-




Рис. 13: Ветвление с чекпойнта (AdamW, GPT-2): три продолжения с разными потоками данных; слева — критерии, справа — валидационная ошибка

чения градиенты предобученной модели малы с первых шагов, и его окно устойчивости практически пусто — в согласии с выводом выше.

Таблица 4: GLUE (валидация), RoBERTa-base: среднее $\pm$ ст. отклонение по 5 запускам; η , λ подобраны для каждого метода

Метод	RTE (acc)	MRPC (F1)	CoLA (MCC)	STS-B (Sp.)	SST-2 (acc)
AdamL2	68.7 ± 2.8	92.0 ± 0.5	59.5 ± 1.2	90.2 ± 0.3	93.1 ± 0.4
AdamW	72.2 ± 10.9	92.5 ± 0.6	64.3 ± 1.6	90.7 ± 0.2	94.5 ± 0.1
AdamWH	53.4 ± 1.3	89.3 ± 0.8	46.5 ± 2.4	77.1 ± 0.6	49.1 ± 0.0

Отметим уточнение к интерпретации послойной адаптивности в режиме дообучения: медианные $\hat{d}^i$ у *верхних* слоёв энкодера примерно в 4 раза меньше, чем у нижних (у верхних слоёв градиенты быстрее затухают по мере подстройки под задачу), поэтому эффективный штраф $\lambda \hat{d}^i$ щадит именно верхние слои. Направление адаптации задаётся распределением градиентов конкретной модели и режима обучения, а не фиксировано архитектурой.

Подводя итог раздела: на всех трёх масштабах — от задач с точно вычислимыми решениями до предобучения языковой модели — методы с затуханием весов оптимизируют изменённую функцию $\tilde{F}_t$ (в согласии с теоремами 1–4

и леммами), обычная регуляризация проигрывает им и по устойчивости к гиперпараметрам, и по итоговому качеству, а масштабированное затухание весов имеет содержательную стационарную точку, но сужающееся с ростом масштаба окно устойчивости; сводка соответствий приведена в таблице 1.

4 Заключение

В работе исследованы методы оптимизации с предобуславливанием и затуханием весов. Основные результаты состоят в следующем.

Во-первых, показано, что затухание весов эквивалентно применению метода с предобуславливанием к изменённой задаче: вместо исходной регуляризованной функции $F = f + r$ метод оптимизирует функцию $\tilde{F}_t = f + \tilde{r}_t$ с адаптивным покоординатным регуляризатором $\nabla \tilde{r}_t = D_t \nabla r$. Доказаны существование и гладкость $\tilde{r}_t$, а также нижняя оценка расстояния между решениями исходной и изменённой задач, показывающая, что эти решения различаются тем сильнее, чем дальше матрица предобуславливания от единичной.

Во-вторых, доказаны четыре теоремы о скорости сходимости. Теорема 1 даёт оценку $\mathcal{O}(1/T)$ на убывание квадрата нормы градиента изменённой функции в невыпуклом детерминированном случае — с точностью до порога, контролируемого параметром импульса β . Теорема 2 устанавливает линейную скорость сходимости к решению изменённой задачи в сильно выпуклом случае для регуляризации Тихонова. Теоремы 3 и 4 переносят оба результата на стохастическую постановку с несмещённым градиентом ограниченной дисперсии: в невыпуклом случае получена скорость $\mathcal{O}(1/\sqrt{T})$, совпадающая по порядку со скоростью стохастического градиентного спуска, а в сильно выпуклом — линейная сходимость до «шумового шара», радиус которого пропорционален шагу и дисперсии градиента.

В-третьих, проведены вычислительные эксперименты на трёх масштабах — от задач с точно вычислимыми решениями через ResNet-18 и ViT-Tiny на CIFAR-10/100 до предобучения GPT-2 (124М параметров) и дообучения RoBERTa-base на GLUE, — иллюстрирующие и количественно подтверждающие теорию: у методов с затуханием весов норма градиента исходной функции стабилизируется на ненулевом уровне, тогда как норма градиента изменённой функции убывает в согласии с доказанными оценками, и это поведение воспроизводится по запускам из разных начальных точек. Показано также, что адаптивная регуляризация автоматически ослабляет штраф для параметров

нормировочных слоёв и эмбедингов (воспроизводя практику ручных списков по-decay), а преимущество отделённого затухания весов в качестве реализуется прежде всего через лучшую достижимую точку оптимизации при сопоставимом обобщении на равном уровне подгонки. Отдельно проанализирован новый, промежуточный способ добавления регуляризации (масштабированное затухание весов, AdamWH/OASISWH): установлены его стационарная точка и порог устойчивости, показано сужение области применимости с ростом масштаба задачи.

Ограничения проведённого анализа задают направления дальнейшей работы: учёт первого момента ($\beta_1 > 0$) и коррекции смещения, присутствующих в практическом Adam; анализ предельного поведения матрицы D_t ; перенос оценок на неограниченные регуляризаторы в невыпуклом случае; масштабирование экспериментов на модели большего размера и стабилизация масштабированного затухания весов (выбор нижней срезки $\alpha \gtrsim \eta\lambda$).

Список литературы

- [1] Olivier Chapelle, Jason Weston, Léon Bottou, and Vladimir Vapnik. Vicinal risk minimization. *Advances in neural information processing systems*, 13, 2000.
- [2] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *nature*, 521(7553):436–444, 2015.
- [3] Pádraig Cunningham, Matthieu Cord, and Sarah Jane Delany. Supervised learning. *Machine learning techniques for multimedia: case studies on organization and retrieval*, pages 21–49, 2008.
- [4] Ryan M Rifkin and Ross A Lippert. Notes on regularized least squares. 2007.
- [5] Shai Shalev-Shwartz and Shai Ben-David. *Understanding machine learning: From theory to algorithms*. Cambridge university press, 2014.
- [6] Herbert Robbins and Sutton Monro. A stochastic approximation method. *The annals of mathematical statistics*, pages 400–407, 1951.
- [7] Léon Bottou. Large-scale machine learning with stochastic gradient descent. In *Proceedings of COMPSTAT’2010: 19th International Conference on Computational Statistics Paris France, August 22-27, 2010 Keynote, Invited and Contributed Papers*, pages 177–186. Springer, 2010.
- [8] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of machine learning research*, 12(7), 2011.
- [9] Guodong Zhang, Chaoqi Wang, Bowen Xu, and Roger Grosse. Three mechanisms of weight decay regularization. *arXiv preprint arXiv:1810.12281*, 2018.

- [10] Zhewei Yao, Amir Gholami, Sheng Shen, Mustafa Mustafa, Kurt Keutzer, and Michael W. Mahoney. Adahessian: An adaptive second order optimizer for machine learning, 2021.
- [11] John E Dennis, Jr and Jorge J Moré. Quasi-newton methods, motivation and theory. *SIAM review*, 19(1):46–89, 1977.
- [12] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [13] Tijmen Tieleman and Geoffrey Hinton. Lecture 6.5 — rmsprop: Divide the gradient by a running average of its recent magnitude. COURSERA: Neural Networks for Machine Learning, 2012.
- [14] Majid Jahani, Sergey Rusakov, Zheng Shi, Peter Richtárik, Michael W Mahoney, and Martin Takáč. Doubly adaptive scaled algorithm for machine learning using second-order information. *arXiv preprint arXiv:2109.05198*, 2021.
- [15] Ashia C Wilson, Rebecca Roelofs, Mitchell Stern, Nati Srebro, and Benjamin Recht. The marginal value of adaptive gradient methods in machine learning. *Advances in neural information processing systems*, 30, 2017.
- [16] Feng Zhu, Hongsheng Li, Wanli Ouyang, Nenghai Yu, and Xiaogang Wang. Learning spatial regularization with image-level supervisions for multi-label image classification. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 5513–5522, 2017.
- [17] Yingbo Zhou, Caiming Xiong, and Richard Socher. Improved regularization techniques for end-to-end speech recognition. *arXiv preprint arXiv:1712.07108*, 2017.
- [18] Tingting Wu, Xiao Ding, Minji Tang, Hao Zhang, Bing Qin, and Ting Liu. Stgn: an implicit regularization method for learning with noisy labels in natural

- language processing. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 7587–7598, 2022.
- [19] Federico Girosi, Michael Jones, and Tomaso Poggio. Regularization theory and neural networks architectures. *Neural computation*, 7(2):219–269, 1995.
 - [20] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
 - [21] Johannes Schneider and Scott Kirkpatrick. *Stochastic optimization*. Springer Science & Business Media, 2007.
 - [22] Daniel P Heyman and Matthew J Sobel. *Stochastic models in operations research: stochastic optimization*, volume 2. Courier Corporation, 2004.
 - [23] James C Spall. Implementation of the simultaneous perturbation algorithm for stochastic optimization. *IEEE Transactions on aerospace and electronic systems*, 34(3):817–823, 1998.
 - [24] Sebastian U Stich. Unified optimal analysis of the (stochastic) gradient method. *arXiv preprint arXiv:1907.04232*, 2019.
 - [25] Elad Hazan, Alexander Rakhlin, and Peter Bartlett. Adaptive online gradient descent. *Advances in Neural Information Processing Systems*, 20, 2007.
 - [26] Sashank J. Reddi, Satyen Kale, and Sanjiv Kumar. On the convergence of adam and beyond, 2019.
 - [27] Alexandre Défossez, Léon Bottou, Francis Bach, and Nicolas Usunier. A simple convergence proof of adam and adagrad. *arXiv preprint arXiv:2003.02395*, 2020.
 - [28] Michael R. Zhang, James Lucas, Geoffrey Hinton, and Jimmy Ba. Lookahead optimizer: k steps forward, 1 step back, 2019.

- [29] Boris Ginsburg, Patrice Castonguay, Oleksii Hrinchuk, Oleksii Kuchaiev, Vitaly Lavrukhin, Ryan Leary, Jason Li, Huyen Nguyen, Yang Zhang, and Jonathan M. Cohen. Stochastic gradient methods with layer-wise adaptive moments for training of deep networks, 2020.
- [30] Abdurakhmon Sadiev, Aleksandr Beznosikov, Abdulla Jasem Almansoori, Dmitry Kamzolov, Rachael Tappenden, and Martin Takáč. Stochastic gradient methods with preconditioned updates. *arXiv preprint arXiv:2206.00285*, 2022.
- [31] Aleksandr Beznosikov, Aibek Alanov, Dmitry Kovalev, Martin Takáč, and Alexander Gasnikov. On scaled methods for saddle point problems. *arXiv preprint arXiv:2206.08303*, 2022.
- [32] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015.
- [33] Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

А Приложение

А.1 Доказательства лемм

Доказательство леммы 1. Напомним, что рекурсии (8) и (9) порождают «сырую» последовательность D_t , а в шаге метода используется срезанная матрица $\hat{D}_t$ с $\hat{D}_t^{ii} = \max\{\alpha, |D_t^{ii}|\}$.

1. Диагональность сохраняется как обоими правилами обновления, так и срезкой, поэтому предположение 2 выполняется для $\hat{D}_t$ при всех t . Далее, по индукции для несрезанной последовательности выполняется $|D_t^{ii}| \leq \Gamma$: для (8)

$$(D_{t+1}^{ii})^2 = \beta(D_t^{ii})^2 + (1 - \beta)(H_t^{ii})^2 \leq \beta\Gamma^2 + (1 - \beta)\Gamma^2 = \Gamma^2,$$

а для (9)

$$|D_{t+1}^{ii}| \leq \beta|D_t^{ii}| + (1 - \beta)|H_t^{ii}| \leq \Gamma,$$

где мы использовали предположение $|H_t^{ii}| \leq \Gamma$ и базу индукции $|D_0^{ii}| \leq \Gamma$. После срезки получаем $\alpha \leq \hat{D}_t^{ii} \leq \Gamma$, то есть $\alpha I \preceq \hat{D}_t \preceq \Gamma I$ — предположение 5.

2. Зафиксируем координату i и обозначим $a = |D_t^{ii}|$, $b = |D_{t+1}^{ii}|$, $M_a = \max\{\alpha, a\}$, $M_b = \max\{\alpha, b\}$. Так как $a, b \geq 0$, имеем $M_a^2 = \max\{\alpha^2, a^2\}$ и $M_b^2 = \max\{\alpha^2, b^2\}$. Функция $x \mapsto \max\{\alpha^2, x\}$ 1-липшицева, поэтому

$$|M_b^2 - M_a^2| = |\max\{\alpha^2, b^2\} - \max\{\alpha^2, a^2\}| \leq |b^2 - a^2|.$$

Используя $M_a, M_b \geq \alpha$, равенство $\hat{D}_{t+1}^{ii} - \hat{D}_t^{ii} = M_b - M_a$ и правило обновления (8), получаем

$$\begin{aligned} |\hat{D}_{t+1}^{ii} - \hat{D}_t^{ii}| &= \frac{|M_b^2 - M_a^2|}{M_b + M_a} \leq \frac{|b^2 - a^2|}{2\alpha} \\ &= \frac{(1 - \beta)|(H_t^{ii})^2 - (D_t^{ii})^2|}{2\alpha} \\ &\leq \frac{(1 - \beta)\Gamma^2}{2\alpha}, \end{aligned}$$

где в последнем переходе использовано, что оба квадрата лежат в отрезке $[0, \Gamma^2]$ (пункт 1). Беря максимум по i , получаем утверждение.

3. Аналогично, для линейного правила (9) используем 1-липшицевость отображения $x \mapsto \max\{\alpha, |x|\}$:

$$\begin{aligned} |\hat{D}_{t+1}^{ii} - \hat{D}_t^{ii}| &\leq |D_{t+1}^{ii} - D_t^{ii}| = (1 - \beta) |H_t^{ii} - D_t^{ii}| \\ &\leq (1 - \beta) (|H_t^{ii}| + |D_t^{ii}|) \leq 2\Gamma(1 - \beta), \end{aligned}$$

где снова использованы границы из пункта 1.

□

Доказательство леммы 2. Используя предположения 1 и 2 и то, что элементы d_t^i не зависят от w , запишем градиент функции $\tilde{r}_t(w) = \sum_{i=1}^d d_t^i r_i(w^i)$:

$$\nabla \tilde{r}_t(w) = \nabla \left(\sum_{i=1}^d d_t^i r_i(w^i) \right) = D_t \begin{pmatrix} r'_1(w^1) \\ \vdots \\ r'_d(w^d) \end{pmatrix} = D_t \nabla r(w).$$

Таким образом, функция с требуемым градиентом существует. Поскольку градиент задан на всём (связном) пространстве $\mathbb{R}^d$, функция $\tilde{r}_t$ определена однозначно с точностью до аддитивной константы.

□

Доказательство леммы 3. По лемме 2 и предположениям 3, 5 для любых $x, y \in \mathbb{R}^d$

$$\begin{aligned} \|\nabla \tilde{r}_t(x) - \nabla \tilde{r}_t(y)\| &= \|D_t (\nabla r(x) - \nabla r(y))\| \leq \|D_t\|_2 \|\nabla r(x) - \nabla r(y)\| \\ &\leq \Gamma L_r \|x - y\|, \end{aligned}$$

где $\|D_t\|_2 \leq \Gamma$ в силу предположения 5. Следовательно, $\tilde{r}_t$ является ΓL_r -гладкой, и для неё выполняется неравенство (7) с $L = \Gamma L_r$. Наконец,

$$\|\nabla \tilde{F}_t(x) - \nabla \tilde{F}_t(y)\| \leq \|\nabla f(x) - \nabla f(y)\| + \|\nabla \tilde{r}_t(x) - \nabla \tilde{r}_t(y)\| \leq (L_f + \Gamma L_r) \|x - y\|,$$

то есть $\tilde{F}_t$ является $\tilde{L}$ -гладкой с $\tilde{L} = L_f + \Gamma L_r$.

□

Доказательство леммы 4. Запишем условия стационарности для решений $\tilde{w}_t^*$ и w^* :

$$\begin{cases} \nabla f(\tilde{w}_t^*) + D_t \nabla r(\tilde{w}_t^*) = 0, \\ \nabla f(w^*) + \nabla r(w^*) = 0. \end{cases}$$

По предположению 3 градиент функции $F = f + r$ липшицев с константой $L_F = L_f + L_r$, откуда

$$\begin{aligned} L_F \|\tilde{w}_t^* - w^*\| &\geq \|\nabla F(\tilde{w}_t^*) - \nabla F(w^*)\| \\ &= \|\nabla f(\tilde{w}_t^*) + \nabla r(\tilde{w}_t^*) - \underbrace{(\nabla f(w^*) + \nabla r(w^*))}_{=0}\| \\ &= \|\nabla r(\tilde{w}_t^*) - D_t \nabla r(\tilde{w}_t^*)\| = \|(I - D_t) \nabla r(\tilde{w}_t^*)\|, \end{aligned}$$

где во втором переходе мы подставили первое условие стационарности. Лемма доказана. $\square$

А.2 Доказательства теорем

Доказательство теоремы 1. В детерминированном случае $g_t = \nabla f(w_t)$ и шаг метода имеет вид

$$w_{t+1} - w_t = -\eta D_t^{-1} \nabla f(w_t) - \eta \nabla r(w_t) = -\eta D_t^{-1} \nabla \tilde{F}_t(w_t). \quad (12)$$

Применим неравенство (7) к L_f -гладкой функции f в точках w_t и w_{t+1} :

$$f(w_{t+1}) \leq f(w_t) + \langle \nabla f(w_t), w_{t+1} - w_t \rangle + \frac{L_f}{2} \|w_{t+1} - w_t\|^2. \quad (13)$$

Из (12) выразим градиент функции f :

$$\nabla f(w_t) = \frac{1}{\eta} D_t (w_t - w_{t+1}) - D_t \nabla r(w_t).$$

Подставим это выражение в (13); по предположению 5 $\|w_{t+1} - w_t\|^2 \leq \frac{1}{\alpha} \|w_{t+1} - w_t\|_{D_t}^2$, поэтому

$$\begin{aligned} f(w_{t+1}) &\leq f(w_t) + \left\langle \frac{1}{\eta} D_t(w_t - w_{t+1}) - D_t \nabla r(w_t), w_{t+1} - w_t \right\rangle \\ &\quad + \frac{L_f}{2\alpha} \|w_{t+1} - w_t\|_{D_t}^2 \\ &= f(w_t) + \left(\frac{L_f}{2\alpha} - \frac{1}{\eta} \right) \|w_{t+1} - w_t\|_{D_t}^2 - \langle D_t \nabla r(w_t), w_{t+1} - w_t \rangle. \end{aligned}$$

По лемме 2 $D_t \nabla r(w_t) = \nabla \tilde{r}_t(w_t)$, а по лемме 3 функция $\tilde{r}_t$ является $L_{\tilde{r}}$ -гладкой с $L_{\tilde{r}} = \Gamma L_r$, то есть

$$\begin{aligned} \tilde{r}_t(w_{t+1}) &\leq \tilde{r}_t(w_t) + \langle \nabla \tilde{r}_t(w_t), w_{t+1} - w_t \rangle + \frac{L_{\tilde{r}}}{2} \|w_{t+1} - w_t\|^2 \\ &\leq \tilde{r}_t(w_t) + \langle \nabla \tilde{r}_t(w_t), w_{t+1} - w_t \rangle + \frac{L_{\tilde{r}}}{2\alpha} \|w_{t+1} - w_t\|_{D_t}^2, \end{aligned}$$

где мы снова использовали $\|\cdot\|^2 \leq \frac{1}{\alpha} \|\cdot\|_{D_t}^2$. Отсюда

$$-\langle \nabla \tilde{r}_t(w_t), w_{t+1} - w_t \rangle \leq \tilde{r}_t(w_t) - \tilde{r}_t(w_{t+1}) + \frac{L_{\tilde{r}}}{2\alpha} \|w_{t+1} - w_t\|_{D_t}^2,$$

и, подставляя в предыдущую оценку,

$$\begin{aligned} f(w_{t+1}) &\leq f(w_t) + \left(\frac{L_f}{2\alpha} - \frac{1}{\eta} \right) \|w_{t+1} - w_t\|_{D_t}^2 \\ &\quad + \tilde{r}_t(w_t) - \tilde{r}_t(w_{t+1}) + \frac{L_{\tilde{r}}}{2\alpha} \|w_{t+1} - w_t\|_{D_t}^2. \end{aligned}$$

Вспоминая определение $\tilde{F}_t(w) := f(w) + \tilde{r}_t(w)$ и обозначая $\tilde{L} = L_f + L_{\tilde{r}} = L_f + \Gamma L_r$, получаем:

$$\tilde{F}_t(w_{t+1}) \leq \tilde{F}_t(w_t) + \left(\frac{\tilde{L}}{2\alpha} - \frac{1}{\eta} \right) \|w_{t+1} - w_t\|_{D_t}^2.$$

Мы выбираем шаг так, что $\frac{\tilde{L}}{2\alpha} - \frac{1}{\eta} < 0 \Leftrightarrow \eta < \frac{2\alpha}{\tilde{L}}$, поэтому

$$\left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha} \right) \|w_{t+1} - w_t\|_{D_t}^2 \leq \tilde{F}_t(w_t) - \tilde{F}_t(w_{t+1}). \quad (14)$$

Заметим, что согласно (12)

$$\begin{aligned}\|w_{t+1} - w_t\|_{D_t}^2 &= \eta^2 \|D_t^{-1} \nabla \tilde{F}_t(w_t)\|_{D_t}^2 = \eta^2 \nabla \tilde{F}_t(w_t)^T D_t^{-1} D_t D_t^{-1} \nabla \tilde{F}_t(w_t) \\ &= \eta^2 \|\nabla \tilde{F}_t(w_t)\|_{D_t^{-1}}^2 \geq \frac{\eta^2}{\Gamma} \|\nabla \tilde{F}_t(w_t)\|^2,\end{aligned}$$

и, подставляя это в (14), получаем

$$\left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha}\right) \frac{\eta^2}{\Gamma} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \tilde{F}_t(w_t) - \tilde{F}_t(w_{t+1}). \quad (15)$$

Далее оценим изменение функции $\tilde{F}_t$ при переходе от t к $t+1$ в фиксированной точке w :

$$\begin{aligned}|\tilde{F}_{t+1}(w) - \tilde{F}_t(w)| &= |\tilde{r}_{t+1}(w) - \tilde{r}_t(w)| = \left| \sum_{i=1}^d (d_{t+1}^i - d_t^i) r_i(w^i) \right| \\ &\leq \sum_{i=1}^d |d_{t+1}^i - d_t^i| r_i(w^i) \leq \|D_{t+1} - D_t\|_{\infty} r(w) \\ &\leq \Omega \|D_{t+1} - D_t\|_{\infty},\end{aligned}$$

где мы использовали неотрицательность r_i (предположение 1) и предположение 4. По лемме 1 $\|D_{t+1} - D_t\|_{\infty} \leq \rho_{\beta}$, поэтому

$$|\tilde{F}_{t+1}(w) - \tilde{F}_t(w)| \leq \Omega \rho_{\beta} = \delta, \quad (16)$$

где δ — та же величина, что и в формулировке теоремы (её значения для (8) и (9) получаются подстановкой ρ_{β} из леммы 1). Теперь оценим убывание по «диагонали», используя (15) и (16):

$$\begin{aligned}\tilde{F}_t(w_t) - \tilde{F}_{t+1}(w_{t+1}) &= \tilde{F}_t(w_t) - \tilde{F}_t(w_{t+1}) + \tilde{F}_t(w_{t+1}) - \tilde{F}_{t+1}(w_{t+1}) \\ &\geq \left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha}\right) \frac{\eta^2}{\Gamma} \|\nabla \tilde{F}_t(w_t)\|^2 - \delta,\end{aligned}$$

то есть

$$\left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha}\right) \frac{\eta^2}{\Gamma} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \tilde{F}_t(w_t) - \tilde{F}_{t+1}(w_{t+1}) + \delta.$$

Просуммируем полученное неравенство по всем итерациям $t = 0, \dots, T$. Сумма в правой части телескопируется:

$$\begin{aligned} \frac{\eta^2(T+1)}{\Gamma} \left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha} \right) \cdot \min_{t \in \overline{0, T}} \|\nabla \tilde{F}_t(w_t)\|^2 &\leq \frac{\eta^2}{\Gamma} \left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha} \right) \cdot \sum_{t=0}^T \|\nabla \tilde{F}_t(w_t)\|^2 \\ &\leq \tilde{F}_0(w_0) - \tilde{F}_{T+1}(w_{T+1}) + \delta \cdot (T+1). \end{aligned}$$

Заметим, что $\tilde{F}_{T+1}(w) = f(w) + \tilde{r}_{T+1}(w) \geq f(w) \geq f^*$, поскольку $\tilde{r}_{T+1}(w) = \sum_i d_{T+1}^i r_i(w^i) \geq 0$ в силу $r_i \geq 0$ (предположение 1) и $d_{T+1}^i \geq \alpha > 0$ (предположение 5). Поэтому правая часть не превосходит $\Delta_0 + \delta(T+1)$, где $\Delta_0 = \tilde{F}_0(w_0) - f^*$, и

$$\min_{t \in \overline{0, T}} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \frac{\Delta_0 \Gamma}{\left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha}\right) \eta^2 (T+1)} + \frac{\delta \Gamma}{\left(\frac{1}{\eta} - \frac{\tilde{L}}{2\alpha}\right) \eta^2}.$$

Приравнивая правую часть к ε и учитывая условие $\varepsilon > \frac{\delta \Gamma}{\eta - \tilde{L}\eta^2/(2\alpha)}$ (без него никакое число итераций не гарантирует ε -точность), получаем

$$T+1 \geq \frac{\Delta_0 \Gamma}{\left(\eta - \frac{\tilde{L}\eta^2}{2\alpha}\right) \left(\varepsilon - \frac{\delta \Gamma}{\eta - \frac{\tilde{L}\eta^2}{2\alpha}}\right)},$$

что и даёт оценку количества шагов, необходимых для достижения заданной точности:

$$T = \mathcal{O} \left(\frac{\Delta_0 \Gamma}{\left(\eta - \frac{\tilde{L}\eta^2}{2\alpha}\right) \left(\varepsilon - \frac{\delta \Gamma}{\eta - \frac{\tilde{L}\eta^2}{2\alpha}}\right)} \right).$$

□

Доказательство теоремы 2. Для регуляризации Тихонова $r(w) = \frac{\lambda}{2} \|w\|^2$ по лемме 2

$$\tilde{r}_t(w) = \frac{\lambda}{2} \sum_{i=1}^d d_t^i (w^i)^2 = \frac{\lambda}{2} \|w\|_{D_t}^2, \quad \nabla \tilde{F}_t(w) = \nabla f(w) + \lambda D_t w.$$

Шаг 0: свойства $\tilde{F}_t$ и её минимизатора. Функция $\tilde{r}_t$ имеет гессиан $\lambda D_t \succcurlyeq \lambda \alpha I$, поэтому вместе с предположением 6 функция $\tilde{F}_t$ является $\tilde{\mu}$ -сильно

выпуклой с $\tilde{\mu} = \mu_f + \lambda\alpha$; её градиент липшицев с константой $\tilde{L} = L_f + \lambda\Gamma$ (лемма 3 с $L_r = \lambda$). Следовательно, минимизатор $\tilde{w}_t^* = \arg \min_w \tilde{F}_t(w)$ существует и единственен, причём $\nabla \tilde{F}_t(\tilde{w}_t^*) = 0$.

Оценим $\|\tilde{w}_t^*\|$. По сильной выпуклости и $\nabla \tilde{F}_t(\tilde{w}_t^*) = 0$:

$$0 = \langle \nabla \tilde{F}_t(\tilde{w}_t^*) - \nabla \tilde{F}_t(0), \tilde{w}_t^* \rangle + \langle \nabla \tilde{F}_t(0), \tilde{w}_t^* \rangle \geq \tilde{\mu} \|\tilde{w}_t^*\|^2 - \|\nabla \tilde{F}_t(0)\| \cdot \|\tilde{w}_t^*\|,$$

а так как $\nabla \tilde{F}_t(0) = \nabla f(0)$, получаем

$$\|\tilde{w}_t^*\| \leq \frac{\|\nabla f(0)\|}{\tilde{\mu}} = \Omega_0 \quad \forall t. \quad (17)$$

Шаг 1: сжатие за один шаг при фиксированных D_t и $\tilde{w}_t^*$. Шаг метода: $w_{t+1} = w_t - \eta D_t^{-1} \nabla \tilde{F}_t(w_t)$. Тогда

$$\|w_{t+1} - \tilde{w}_t^*\|_{D_t}^2 = \|w_t - \tilde{w}_t^*\|_{D_t}^2 - 2\eta \langle \nabla \tilde{F}_t(w_t), w_t - \tilde{w}_t^* \rangle + \eta^2 \|\nabla \tilde{F}_t(w_t)\|_{D_t^{-1}}^2.$$

Оценим второй член через сильную выпуклость ($\nabla \tilde{F}_t(\tilde{w}_t^*) = 0$) и предположение 5:

$$\langle \nabla \tilde{F}_t(w_t), w_t - \tilde{w}_t^* \rangle \geq \tilde{\mu} \|w_t - \tilde{w}_t^*\|^2 \geq \frac{\tilde{\mu}}{\Gamma} \|w_t - \tilde{w}_t^*\|_{D_t}^2,$$

а третий — через липшицевость градиента:

$$\|\nabla \tilde{F}_t(w_t)\|_{D_t^{-1}}^2 \leq \frac{1}{\alpha} \|\nabla \tilde{F}_t(w_t) - \nabla \tilde{F}_t(\tilde{w}_t^*)\|^2 \leq \frac{\tilde{L}^2}{\alpha} \|w_t - \tilde{w}_t^*\|^2 \leq \frac{\tilde{L}^2}{\alpha^2} \|w_t - \tilde{w}_t^*\|_{D_t}^2.$$

Итого

$$\|w_{t+1} - \tilde{w}_t^*\|_{D_t}^2 \leq \left(1 - \frac{2\eta\tilde{\mu}}{\Gamma} + \frac{\eta^2\tilde{L}^2}{\alpha^2}\right) \|w_t - \tilde{w}_t^*\|_{D_t}^2 \leq \left(1 - \frac{\eta\tilde{\mu}}{\Gamma}\right) \|w_t - \tilde{w}_t^*\|_{D_t}^2,$$

где в последнем переходе использовано условие $\eta \leq \frac{\tilde{\mu}\alpha^2}{\Gamma\tilde{L}^2}$, дающее $\frac{\eta^2\tilde{L}^2}{\alpha^2} \leq \frac{\eta\tilde{\mu}}{\Gamma}$.

Шаг 2: дрейф минимизатора. Вычтем условия стационарности для шагов t и $t+1$:

$$[\nabla f(\tilde{w}_{t+1}^*) - \nabla f(\tilde{w}_t^*)] + \lambda D_{t+1} (\tilde{w}_{t+1}^* - \tilde{w}_t^*) = -\lambda (D_{t+1} - D_t) \tilde{w}_t^*.$$

Скалярно умножим обе части на $\tilde{w}_{t+1}^* - \tilde{w}_t^*$. Левая часть не меньше $(\mu_f + \lambda\alpha) \|\tilde{w}_{t+1}^* - \tilde{w}_t^*\|^2 = \tilde{\mu} \|\tilde{w}_{t+1}^* - \tilde{w}_t^*\|^2$ (сильная выпуклость f и $D_{t+1} \succcurlyeq \alpha I$), правая

по неравенству Коши–Буняковского и лемме 1 не превосходит $\lambda\rho_\beta\Omega_0\|\tilde{w}_{t+1}^* - \tilde{w}_t^*\|$, где мы использовали (17). Следовательно,

$$\|\tilde{w}_{t+1}^* - \tilde{w}_t^*\| \leq \frac{\lambda\rho_\beta\Omega_0}{\tilde{\mu}}. \quad (18)$$

Шаг 3: рекурсия для R_t^2 . Обозначим $s := \frac{\eta\tilde{\mu}}{4\Gamma}$ и заметим, что $s \leq \frac{1}{4}$ (действительно, $\frac{\eta\tilde{\mu}}{\Gamma} \leq \frac{\tilde{\mu}^2\alpha^2}{\Gamma^2\tilde{L}^2} \leq 1$, так как $\tilde{\mu} \leq \tilde{L}$ и $\alpha \leq \Gamma$). Переход к норме следующего шага: по лемме 1 и предположению 5

$$\|x\|_{D_{t+1}}^2 \leq \|x\|_{D_t}^2 + \|D_{t+1} - D_t\|_\infty \|x\|^2 \leq \left(1 + \frac{\rho_\beta}{\alpha}\right) \|x\|_{D_t}^2,$$

причём по условию теоремы $\frac{\rho_\beta}{\alpha} \leq \frac{\eta\tilde{\mu}}{4\Gamma} = s$. Комбинируя неравенство Юнга $\|a + b\|_{D_t}^2 \leq (1 + \theta)\|a\|_{D_t}^2 + (1 + \frac{1}{\theta})\|b\|_{D_t}^2$ с $\theta = s$, оценку шага 1, оценку дрейфа (18) и $\|\cdot\|_{D_t}^2 \leq \Gamma\|\cdot\|^2$, получаем

$$\begin{aligned} R_{t+1}^2 &= \|w_{t+1} - \tilde{w}_{t+1}^*\|_{D_{t+1}}^2 \leq (1 + s)(1 + s)\|w_{t+1} - \tilde{w}_t^*\|_{D_t}^2 \\ &\quad + (1 + s) \left(1 + \frac{1}{s}\right) \Gamma \left(\frac{\lambda\rho_\beta\Omega_0}{\tilde{\mu}}\right)^2 \\ &\leq (1 + s)^2 (1 - 4s) R_t^2 \\ &\quad + (1 + s) \left(1 + \frac{1}{s}\right) \Gamma \left(\frac{\lambda\rho_\beta\Omega_0}{\tilde{\mu}}\right)^2. \end{aligned}$$

Так как $s \leq \frac{1}{4}$, непосредственной проверкой убеждаемся, что $(1 + s)^2(1 - 4s) \leq 1 - s$ и $(1 + s)(1 + 1/s) \leq 4/s$, поэтому

$$R_{t+1}^2 \leq (1 - s) R_t^2 + \frac{4\Gamma}{s} \left(\frac{\lambda\rho_\beta\Omega_0}{\tilde{\mu}}\right)^2.$$

Шаг 4: разворачивание рекурсии. Стандартным образом для рекурсии $R_{t+1}^2 \leq (1 - s)R_t^2 + c$ получаем $R_T^2 \leq (1 - s)^T R_0^2 + \frac{c}{s}$, откуда

$$R_T^2 \leq \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \frac{4\Gamma}{s^2} \left(\frac{\lambda\rho_\beta\Omega_0}{\tilde{\mu}}\right)^2 = \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \frac{64\Gamma^3\lambda^2\Omega_0^2}{\eta^2\tilde{\mu}^4} \rho_\beta^2.$$

Наконец, если β выбран так, что второе слагаемое не превосходит $\frac{\varepsilon}{2}$, то из $(1 - s)^T \leq e^{-sT}$ следует, что $R_T^2 \leq \varepsilon$ при $T \geq \frac{1}{s} \log \frac{2R_0^2}{\varepsilon} = \frac{4\Gamma}{\eta\tilde{\mu}} \log \frac{2R_0^2}{\varepsilon}$. $\square$

Доказательство теоремы 3. Шаг метода: $w_{t+1} = w_t - \eta D_t^{-1} \hat{g}_t$, где $\hat{g}_t = g_t + D_t \nabla r(w_t)$. Обозначим $\mathbb{E}_t[\cdot] := \mathbb{E}[\cdot \mid \mathcal{F}_t]$. По предположению 7 величины w_t и D_t $\mathcal{F}_t$ -измеримы, поэтому

$$\mathbb{E}_t[\hat{g}_t] = \nabla \tilde{F}_t(w_t), \quad \mathbb{E}_t \|\hat{g}_t - \nabla \tilde{F}_t(w_t)\|^2 \leq \sigma^2.$$

По лемме 3 функция $\tilde{F}_t$ является $\tilde{L}$ -гладкой, поэтому по (7)

$$\tilde{F}_t(w_{t+1}) \leq \tilde{F}_t(w_t) - \eta \langle \nabla \tilde{F}_t(w_t), D_t^{-1} \hat{g}_t \rangle + \frac{\tilde{L} \eta^2}{2} \|D_t^{-1} \hat{g}_t\|^2.$$

Возьмём условное ожидание $\mathbb{E}_t$. Для линейного члена, используя несмещённость и 5,

$$\mathbb{E}_t \langle \nabla \tilde{F}_t(w_t), D_t^{-1} \hat{g}_t \rangle = \langle \nabla \tilde{F}_t(w_t), D_t^{-1} \nabla \tilde{F}_t(w_t) \rangle \geq \frac{1}{\Gamma} \|\nabla \tilde{F}_t(w_t)\|^2.$$

Для квадратичного члена, используя $\|D_t^{-1} x\| \leq \frac{1}{\alpha} \|x\|$ и разложение дисперсии $\mathbb{E}_t \|\hat{g}_t\|^2 = \|\nabla \tilde{F}_t(w_t)\|^2 + \mathbb{E}_t \|\hat{g}_t - \nabla \tilde{F}_t(w_t)\|^2$,

$$\mathbb{E}_t \|D_t^{-1} \hat{g}_t\|^2 \leq \frac{1}{\alpha^2} \left(\|\nabla \tilde{F}_t(w_t)\|^2 + \sigma^2 \right).$$

Итого

$$\begin{aligned} \mathbb{E}_t [\tilde{F}_t(w_{t+1})] &\leq \tilde{F}_t(w_t) - \left(\frac{\eta}{\Gamma} - \frac{\tilde{L} \eta^2}{2\alpha^2} \right) \|\nabla \tilde{F}_t(w_t)\|^2 + \frac{\tilde{L} \eta^2 \sigma^2}{2\alpha^2} \\ &\leq \tilde{F}_t(w_t) - \frac{\eta}{2\Gamma} \|\nabla \tilde{F}_t(w_t)\|^2 + \frac{\tilde{L} \eta^2 \sigma^2}{2\alpha^2}, \end{aligned}$$

где в последнем переходе использовано условие $\eta \leq \frac{\alpha^2}{\tilde{L}}$, дающее $\frac{\tilde{L} \eta^2}{2\alpha^2} \leq \frac{\eta}{2\Gamma}$.

Дрейф функции $\tilde{F}_t$ по t оценивается в точности как в доказательстве теоремы 1 (неравенство (16) выполняется с вероятностью 1): $\tilde{F}_{t+1}(w_{t+1}) \leq \tilde{F}_t(w_{t+1}) + \delta$.

Беря полное математическое ожидание и складывая, получаем

$$\mathbb{E} [\tilde{F}_{t+1}(w_{t+1})] \leq \mathbb{E} [\tilde{F}_t(w_t)] - \frac{\eta}{2\Gamma} \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 + \frac{\tilde{L} \eta^2 \sigma^2}{2\alpha^2} + \delta.$$

Суммируя по $t = 0, \dots, T$ и используя, как в доказательстве теоремы 1, оценку $\mathbb{E}[\tilde{F}_{T+1}(w_{T+1})] \geq f^*$, получаем

$$\frac{\eta}{2\Gamma} \sum_{t=0}^T \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \Delta_0 + (T+1) \left(\frac{\tilde{L} \eta^2 \sigma^2}{2\alpha^2} + \delta \right),$$

откуда, заменяя минимум средним,

$$\begin{aligned} \min_{0 \leq t \leq T} \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 &\leq \frac{1}{T+1} \sum_{t=0}^T \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 \\ &\leq \frac{2\Gamma\Delta_0}{\eta(T+1)} + \frac{\Gamma\tilde{L}\eta\sigma^2}{\alpha^2} + \frac{2\Gamma\delta}{\eta}. \end{aligned}$$

□

Доказательство теоремы 4. Доказательство повторяет схему теоремы 2 с учётом стохастичности градиента. Шаги 0 и 2 (свойства $\tilde{F}_t$, оценка $\|\tilde{w}_t^*\| \leq \Omega_0$ и дрейф (18)) не зависят от способа вычисления градиента и переносятся без изменений.

Сжатие за один шаг. Шаг метода: $w_{t+1} = w_t - \eta D_t^{-1} \hat{g}_t$; как и в доказательстве теоремы 3, при $\mathbb{E}_t[\cdot] = \mathbb{E}[\cdot \mid \mathcal{F}_t]$ имеем $\mathbb{E}_t[\hat{g}_t] = \nabla \tilde{F}_t(w_t)$ и $\mathbb{E}_t \|\hat{g}_t - \nabla \tilde{F}_t(w_t)\|^2 \leq \sigma^2$. Тогда

$$\mathbb{E}_t \|w_{t+1} - \tilde{w}_t^*\|_{D_t}^2 = \|w_t - \tilde{w}_t^*\|_{D_t}^2 - 2\eta \langle \nabla \tilde{F}_t(w_t), w_t - \tilde{w}_t^* \rangle + \eta^2 \mathbb{E}_t \|\hat{g}_t\|_{D_t^{-1}}^2,$$

где мы использовали $\langle D_t^{-1} \hat{g}_t, w_t - \tilde{w}_t^* \rangle_{D_t} = \langle \hat{g}_t, w_t - \tilde{w}_t^* \rangle$ и условную несмещённость $\hat{g}_t$. Как и в теореме 2, $\langle \nabla \tilde{F}_t(w_t), w_t - \tilde{w}_t^* \rangle \geq \frac{\tilde{\mu}}{\Gamma} \|w_t - \tilde{w}_t^*\|_{D_t}^2$, а для квадратичного члена

$$\begin{aligned} \mathbb{E}_t \|\hat{g}_t\|_{D_t^{-1}}^2 &\leq \frac{1}{\alpha} \mathbb{E}_t \|\hat{g}_t\|^2 = \frac{1}{\alpha} \left(\|\nabla \tilde{F}_t(w_t)\|^2 + \mathbb{E}_t \|\hat{g}_t - \nabla \tilde{F}_t(w_t)\|^2 \right) \\ &\leq \frac{\tilde{L}^2}{\alpha^2} \|w_t - \tilde{w}_t^*\|_{D_t}^2 + \frac{\sigma^2}{\alpha}. \end{aligned}$$

При $\eta \leq \frac{\tilde{\mu}\alpha^2}{\Gamma\tilde{L}^2}$ получаем

$$\mathbb{E}_t \|w_{t+1} - \tilde{w}_t^*\|_{D_t}^2 \leq \left(1 - \frac{\eta\tilde{\mu}}{\Gamma}\right) \|w_t - \tilde{w}_t^*\|_{D_t}^2 + \frac{\eta^2\sigma^2}{\alpha}.$$

Рекурсия и итог. Обозначая $s = \frac{\eta\tilde{\mu}}{4\Gamma} \leq \frac{1}{4}$ и повторяя шаг 3 теоремы 2 (смена нормы и дрейф цели; шумовой член при этом умножается на $(1+s)^2 \leq 2$), получаем

$$\mathbb{E} [R_{t+1}^2] \leq (1-s) \mathbb{E} [R_t^2] + \frac{2\eta^2\sigma^2}{\alpha} + \frac{4\Gamma}{s} \left(\frac{\lambda\rho_\beta\Omega_0}{\tilde{\mu}} \right)^2.$$

Разворачивая рекурсию ($R_T^2 \leq (1 - s)^T R_0^2 + \frac{c}{s}$ для $R_{t+1}^2 \leq (1 - s)R_t^2 + c$), получаем

$$\begin{aligned} \mathbb{E}[R_T^2] &\leq \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \frac{8\Gamma\eta\sigma^2}{\tilde{\mu}\alpha} \\ &\quad + \frac{64\Gamma^3\lambda^2\Omega_0^2}{\eta^2\tilde{\mu}^4} \rho_\beta^2. \end{aligned}$$

Для достижения $\mathbb{E}[R_T^2] \leq \varepsilon$ достаточно сделать каждое из трёх слагаемых не превосходящим $\frac{\varepsilon}{3}$: первое — за $T \geq \frac{4\Gamma}{\eta\tilde{\mu}} \log \frac{3R_0^2}{\varepsilon}$ итераций, второе — выбором $\eta \leq \frac{\varepsilon\tilde{\mu}\alpha}{24\Gamma\sigma^2}$, третье — выбором β , достаточно близкого к 1 (так как $\rho_\beta \rightarrow 0$ при $\beta \rightarrow 1$). $\square$