

Методы предобуславливания с затуханием весов

Выпускная квалификационная работа бакалавра

Матвей Вадимович Крейнин

Научный руководитель: к.ф.-м.н. А. Н. Безносиков

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 03.03.01 Прикладные математика и физика

2024

Методы предобуславливания с затуханием весов

Исследуется сходимость методов оптимизации с предобуславливанием (Adam, OASIS), использующих регуляризацию с затуханием весов.

Проблема

К решению какой задачи и с какой скоростью сходятся методы с предобуславливанием при разных способах добавления регуляризации.

Цель

Доказать оценки скорости сходимости (в детерминированной и стохастической постановках), охарактеризовать предельную точку, исследовать новый способ добавления регуляризации и проверить теорию экспериментально.

Постановка задачи

Задача обучения

$$\min_{w \in \mathbb{R}^d} f(w)$$

Градиентный спуск:

$$w_{t+1} = w_t - \eta \nabla f(w_t).$$

Метод Ньютона:

$$w_{t+1} = w_t - \eta (\nabla^2 f(w_t))^{-1} \nabla f(w_t).$$

Стохастический градиент:

$$w_{t+1} = w_t - \eta g_t, \quad \mathbb{E}[g_t] = \nabla f(w_t).$$

С предобуславливанием:

$$w_{t+1} = w_t - \eta D_t^{-1} g_t.$$

D_t — диагональная матрица предобуславливания: Adam строит её по квадратам стохастических градиентов, OASIS — по оценке диагонали гессiana.

Три способа добавления регуляризации

Регуляризованная задача: $\min_{w \in \mathbb{R}^d} F(w) := f(w) + r(w)$, r — функция регуляризации.

Algorithm 1 Способы использования предобуславливания с регуляризацией

Require: η — шаг обучения, f — функция потерь, r — регуляризатор, w_0 — начальная точка

while w не сойдётся **do**

$t = t + 1$

$g_t \leftarrow$ стохастический градиент f в точке w_{t-1}

$g_t \leftarrow g_t + \nabla r(w_{t-1})$ обычная регуляризация (L2)

$D_t \leftarrow$ матрица предобуславливания, построенная по g_t

$w_t \leftarrow w_{t-1} - \eta \cdot D_t^{-1} g_t$ обычная регуляризация (L2)

$w_t \leftarrow w_{t-1} - \eta \cdot D_t^{-1} (g_t + \nabla r(w_{t-1}))$ масштабированное затухание весов (WH)

$w_t \leftarrow w_{t-1} - \eta \cdot D_t^{-1} g_t - \eta \cdot \nabla r(w_{t-1})$ затухание весов (W)

end while

Масштабированное затухание весов (WH) — новый, промежуточный способ: D_t строится без регуляризатора, но ∇r масштабируется матрицей D_t^{-1} .

Альтернативный взгляд: изменённая задача

Вынесем D_t^{-1} за скобки в шаге затухания весов:

$$w_{t+1} = w_t - \eta D_t^{-1} (\nabla f(w_t) + D_t \nabla r(w_t)).$$

Введём $\tilde{r}_t$ с $\nabla \tilde{r}_t(w) = D_t \nabla r(w)$. Метод делает шаг по градиенту функции

$$\tilde{F}_t(w) := f(w) + \tilde{r}_t(w),$$

которая меняется на каждой итерации вместе с D_t .

Лемма (существование $\tilde{r}_t$)

Если r сепарабелен, а D_t диагональна, то $\tilde{r}_t$ существует:

$$\tilde{r}_t(w) = \sum_{i=1}^d d_t^i r_i(w^i).$$

Лемма (L -гладкость $\tilde{r}_t$)

Если вдобавок r является L_r -гладким, а $\alpha I \preceq D_t \preceq \Gamma I$, то $\tilde{r}_t$ является ΓL_r -гладкой, а $\tilde{F}_t$ — $\tilde{L}$ -гладкой с $\tilde{L} = L_f + \Gamma L_r$.

Предположения

1. Структура регуляризатора

r сепарабелен: $r(w) = \sum_{i=1}^d r_i(w^i)$,
где $r_i(x) \geq 0$.

2. Диагональность D_t

$$D_t = \text{diag} \{d_t^1, \dots, d_t^d\}.$$

3. Ограниченность D_t

$$\exists 0 < \alpha < \Gamma: \alpha I \preccurlyeq D_t \preccurlyeq \Gamma I.$$

4. L -гладкость f и r

Градиенты f и r липшицевы с константами L_f и L_r .

5. Ограниченность r

$|r(w)| \leq \Omega$ — только для невыпуклого случая (теоремы 1 и 3).

6. Сильная выпуклость f

Только для теорем 2 и 4: $\exists \mu_f > 0$ такое, что $\forall x, y$

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu_f}{2} \|x - y\|^2.$$

Эволюция матрицы предобуславливания

Два правила обновления с параметром импульса $\beta \in [0, 1]$ и срезкой

$$\hat{D}_{t+1}^{ii} = \max\{\alpha, |D_{t+1}^{ii}|\}:$$

$$\underbrace{(D_{t+1})^2 = \beta(D_t)^2 + (1 - \beta)(H_t)^2,}_{\text{квадраты: Adam, RMSProp}}$$

$$\underbrace{D_{t+1} = \beta D_t + (1 - \beta)H_t.}_{\text{первые степени: OASIS}}$$

Лемма (эволюция D_t)

Пусть H_t диагональны, $|H_t^{ii}| \leq \Gamma$, для $\hat{D}_0$ выполнены предположения 2–3. Тогда предположения 2–3 выполняются для $\hat{D}_t$ при всех t и

$$\|\hat{D}_{t+1} - \hat{D}_t\|_\infty \leq \rho_\beta := \begin{cases} \frac{(1-\beta)\Gamma^2}{2\alpha} & \text{для квадратов,} \\ 2(1-\beta)\Gamma & \text{для первых степеней.} \end{cases}$$

При $\beta \rightarrow 1$ имеем $\rho_\beta \rightarrow 0$: дрейф изменённой задачи $\tilde{F}_t$ контролируем; именно ρ_β входит в остаточные члены всех четырёх теорем.

К какому решению сходится метод

Методы с затуханием весов сходятся не к решению w^* исходной задачи $\min_w F(w)$, а к решению $\tilde{w}_t^* = \arg \min_w \tilde{F}_t(w)$ изменённой задачи.

Лемма (нижняя оценка расстояния между решениями)

Пусть выполнены предположения 1, 2, 4, исходная задача имеет решение w^ , а изменённая задача при фиксированном t — решение $\tilde{w}_t^*$. Тогда*

$$L_F \|\tilde{w}_t^* - w^*\| \geq \|(I - D_t) \nabla r(\tilde{w}_t^*)\|, \quad L_F = L_f + L_r.$$

- ▶ Решения различаются тем сильнее, чем дальше D_t от единичной матрицы; при $D_t = I$ правая часть обращается в нуль.
- ▶ Механизм: эффективный по координатам штраф λd_t^i мал там, где градиенты малы, — затухание весов почти не штрафует «редкие» координаты.

Сходимость: невыпуклый детерминированный случай

Теорема 1

Пусть выполнены предположения 1–5, $g_t = \nabla f(w_t)$, матрица обновляется по условиям леммы об эволюции D_t , а шаг удовлетворяет $\eta < \frac{2\alpha}{\tilde{L}}$, $\tilde{L} = L_f + \Gamma L_r$.

Обозначим $\Delta_0 = \tilde{F}_0(w_0) - f^*$ и $\delta := \Omega\rho_\beta$. Тогда для любой точности $\varepsilon > \frac{\delta\Gamma}{\eta - \tilde{L}\eta^2/(2\alpha)}$ число итераций до $\min_{0 \leq t \leq T} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \varepsilon$ ограничено величиной

$$T = \mathcal{O} \left(\frac{\Delta_0 \Gamma}{\left(\eta - \frac{\tilde{L}\eta^2}{2\alpha}\right) \left(\varepsilon - \frac{\delta\Gamma}{\eta - \frac{\tilde{L}\eta^2}{2\alpha}}\right)} \right).$$

- ▶ Скорость $\mathcal{O}(1/T)$ по квадрату нормы градиента изменённой функции $\tilde{F}_t$.
- ▶ Порог $\delta = \Omega\rho_\beta \propto (1 - \beta)$ — цена нестационарности $\tilde{F}_t$; выбором $\beta \rightarrow 1$ делается сколь угодно малым.

Сходимость: сильно выпуклый случай

Теорема 2

Пусть выполнены предположения 2–4, 6, $r(w) = \frac{\lambda}{2} \|w\|^2$, $g_t = \nabla f(w_t)$. Обозначим $\tilde{\mu} = \mu_f + \lambda\alpha$, $\tilde{L} = L_f + \lambda\Gamma$, $\Omega_0 = \|\nabla f(0)\|/\tilde{\mu}$, $R_t^2 = \|w_t - \tilde{w}_t^*\|_{D_t}^2$. Пусть $0 < \eta \leq \frac{\tilde{\mu}\alpha^2}{\Gamma\tilde{L}^2}$ и $\rho_\beta \leq \frac{\eta\tilde{\mu}\alpha}{4\Gamma}$. Тогда для всех $T \geq 1$

$$R_T^2 \leq \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \frac{64\Gamma^3\lambda^2\Omega_0^2}{\eta^2\tilde{\mu}^4} \rho_\beta^2.$$

- ▶ Линейная скорость: $R_T^2 \leq \varepsilon$ за $T = \mathcal{O}\left(\frac{\Gamma}{\eta\tilde{\mu}} \log \frac{R_0^2}{\varepsilon}\right)$ итераций при подходящем β .
- ▶ Сходимость к $\tilde{w}_t^*$ — движущейся цели, а не к w^* (согласовано с леммой о нижней оценке).
- ▶ Остаток $\propto \rho_\beta^2$ исчезает при $\beta \rightarrow 1$ или замороженной D_t .

Сходимость: стохастический случай

Стохастический градиент: $\mathbb{E}[g_t | \mathcal{F}_t] = \nabla f(w_t)$, $\mathbb{E}[\|g_t - \nabla f(w_t)\|^2 | \mathcal{F}_t] \leq \sigma^2$, матрица D_t предсказуема ($\mathcal{F}_t$ -измерима, «запаздывающий» предобуславливатель).

Теорема 3 (невыпуклый случай)

В условиях теоремы 1 со стохастическим градиентом и $0 < \eta \leq \frac{\alpha^2}{\Gamma L}$:

$$\min_{0 \leq t \leq T} \mathbb{E} \|\nabla \tilde{F}_t(w_t)\|^2 \leq \underbrace{\frac{2\Gamma\Delta_0}{\eta(T+1)}}_{\text{оптимизация}} + \underbrace{\frac{\Gamma\tilde{L}\eta\sigma^2}{\alpha^2}}_{\text{шум}} + \underbrace{\frac{2\Gamma\delta}{\eta}}_{\text{дрейф}}.$$

Теорема 4 (сильно выпуклый случай)

В условиях теоремы 2 со стохастическим градиентом:

$$\mathbb{E}[R_T^2] \leq \left(1 - \frac{\eta\tilde{\mu}}{4\Gamma}\right)^T R_0^2 + \underbrace{\frac{8\Gamma\eta\sigma^2}{\tilde{\mu}\alpha}}_{\text{шумовой шар}} + \frac{64\Gamma^3\lambda^2\Omega_0^2}{\eta^2\tilde{\mu}^4} \rho_\beta^2.$$

При оптимальном шаге теорема 3 даёт $\mathcal{O}(1/\sqrt{T})$ — порядок скорости SGD в невыпуклом случае.

Практические алгоритмы: семейство Adam

Algorithm 2 Различные способы добавления регуляризации для Adam

Require: $\eta, \beta_1, \beta_2, \epsilon$ — гиперпараметры, f — функция потерь, r — регуляризатор, w_0
 $m_0 = 0, v_0 = 0, t = 0$

while w не сойдётся **do**

$t = t + 1$

$g_t = \nabla f(w_{t-1}) + \nabla r(w_{t-1})$

AdamL2

$m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$

$v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$

$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} + \nabla r(w_{t-1})$

AdamWH

$\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$

$w_t = w_{t-1} - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}} - \eta \nabla r(w_{t-1})$

AdamW

end while

Аналогично строится семейство OASIS (OASISL2, OASISWH, OASISW), в котором D_t — стохастическая оценка диагонали гессиана.


Масштабированное затухание весов (WN): свойства

- ▶ **Стационарная точка** — решение w^* исходной задачи: условие $\hat{D}_t^{-1}(\nabla f + \nabla r) = 0$ эквивалентно $\nabla F = 0$; при этом регуляризатор не искажает D_t (в отличие от L2).
- ▶ **Порог устойчивости**: на координатах с малым градиентом $\hat{D}_t$ упирается в срезку α , эффективный шаг по регуляризатору возрастает до $\eta\lambda/\alpha$; необходимое условие устойчивости: $\eta\lambda/\alpha < 2$.

α	$\eta\lambda/\alpha$	Предсказание (> 2 — расходимость)	Наблюдение
10^{-8}	$3 \cdot 10^5$	расходится	расходится
10^{-4}	30	расходится	расходится
$3 \cdot 10^{-3}$	1	устойчив	устойчив
10^{-1}	0.03	устойчив	устойчив

Практический вывод: WN требует $\alpha \gtrsim \eta\lambda$; с ростом масштаба задачи рабочее окно λ сужается (на предобучении языковых моделей — исчезает).


Эксперименты: малые задачи (проверка теории)



Семейство Adam, логистическая регрессия (mushrooms): у AdamW $\|\nabla F\|^2$ стабилизируется, а $\|\nabla \tilde{F}_t\|^2$ убывает на 10–16 порядков; у AdamL2 — зеркально. Медиана и разброс по 5 запускам.


- ▶ Лемма о нижней оценке: 27 конфигураций — 0 нарушений; корреляция d^i с частотой признака 0.876.
- ▶ Теорема 2: линейная сходимость к $\tilde{w}_t^*$ до машинной точности; эмпирическая скорость выше гарантии в 11–207 раз.
- ▶ Теоремы 3–4: плато $\propto \eta \sigma^2$, измеренные наклоны 1.00–1.03.

Эксперименты: нейронные сети (CIFAR-10/100)



- ▶ ResNet-18, CIFAR-10, 90 прогонов: AdamW — лучший ($93.9 \pm 0.3\%$) и нечувствителен к λ на пяти порядках («развязка» η и λ); у AdamL2 оптимум диагонален; AdamWH обрушивается вдоль $\eta\lambda \approx \text{const}$ — порог устойчивости.
- ▶ Эффект критериев воспроизводится на всей сети: $\|\nabla F\|^2 / \|\nabla \tilde{F}_t\|^2$ до $3.3 \cdot 10^4$ к концу обучения.
- ▶ CIFAR-100: AdamW превосходит AdamL2 на +1.8 п.п. (ResNet-18) и +6.3 п.п. (ViT-Tiny); преимущество реализуется через лучшую достижимую точку оптимизации.

Эксперименты: GPT-2 124M и GLUE



Предобучение на FineWeb-Edu (1.5 млрд токенов, 2 запуска на метод): AdamW 3.492, AdamL2 6.68; AdamWH расходится при всех испытанных (η, λ) .

- ▶ Авто-«no-decay»: отношение критериев в конце обучения — LayerNorm 450–1400, эмбединги ≈ 14 , attention/MLP 1.5–3: адаптивная регуляризация сама отключает штраф там, где градиенты малы.
- ▶ Рестарты с чекпойнта (3 ветки): поведение критериев совпадает до второго знака — эффект является свойством метода, а не траектории.
- ▶ GLUE (RoBERTa-base, 5 задач): AdamW $\geq$ AdamL2 всюду, на CoLA и STS-B — статистически значимо ($p \approx 0.01$); AdamWH отстаёт везде.

На защиту выносятся

1. Интерпретация затухания весов как оптимизации изменённой задачи $\tilde{F}_t = f + \tilde{r}_t$; леммы о существовании, гладкости $\tilde{r}_t$ и эволюции матрицы D_t .
2. Лемма о нижней оценке расстояния между решениями исходной и изменённой задач.
3. Четыре теоремы о скорости сходимости методов с предобуславливанием и затуханием весов: невыпуклый и сильно выпуклый случаи, каждый — в детерминированной и стохастической постановках.
4. Анализ нового способа регуляризации (масштабированное затухание весов): стационарная точка и порог устойчивости $\eta\lambda/\alpha < 2$.
5. Экспериментальная проверка теории на трёх масштабах: задачи с точными решениями, ResNet/ViT на CIFAR-10/100, GPT-2 124M и GLUE.